

# 바이러스 변이 핫스팟 탐지를 위한 다중 정보원 유형의 체계적 벤치마킹

## 학위논문 요약서

**한줄 요약:** 바이러스 변이 핫스팟을 잘 찾으려면 “가장 멋진 알고리즘 하나”를 고르는 것보다, **그 바이러스에 맞는 생물학적 정보를 고르는 것이 더 중요했습니다.** 11 개 RNA 바이러스에서 8,580 번 비교해 보니, 어떤 정보가 유용한지는 바이러스마다 크게 달랐고 (정보 유형  $\times$  바이러스 효과가 가장 큰 요인,  $\omega^2=0.296$ ), HIV-1 에서는 백신 회피 위치를 무작위보다 7.19 배 더 잘 모아 찾아 실용 가능성도 확인했습니다. PAHD-R 은 이 결론을 바탕으로 후보 위치를 고르는 세 가지 사용 모드 (Core/Augmented/Review) 로 정리했고, 더 공격적인 변형들은 아직 “가능성은 있지만 추가 검증이 필요한 후보” 로 남겼습니다.

**이 한줄의 쉬운 뜻:** 코로나에서 잘 맞는 방법이 독감이나 HIV 에서도 그대로 잘 맞는다고 볼 수 없습니다. 바이러스마다 변이가 생기는 방식과 중요한 단백질 부위가 다르기 때문에, 먼저 “이 바이러스에는 어떤 정보가 믿을 만한가?” 를 고르는 절차가 필요합니다.

**현재 위치 (외부 비교):** ViroGym, EVEREST, ProteinGym 같은 최신 연구는 주로 “개별 변이 하나가 얼마나 해로운가/유리한가” 를 예측합니다. 반면 MutBench 는 “실험자가 먼저 봐야 할 변이 집중 영역이 어디인가” 를 찾습니다. 즉 경쟁 연구라기보다 서로 보완 관계입니다.

**논문 구조:** Ch1 서론  $\rightarrow$  Ch2 관련 연구  $\rightarrow$  Ch3 재료 및 방법  $\rightarrow$  Ch4 실험 결과  $\rightarrow$  Ch5 논의  $\rightarrow$  Ch6 결론

## Chapter 1. Introduction (서론)

### 1.1 Research Background (연구 배경)

바이러스는 세포 안에서 자신의 유전자를 복사하여 증식합니다. 복제 과정에서 간혹 복사 오류가 발생하는데, 이것이 **변이 (mutation)** 입니다. RNA 바이러스 (코로나, 인플루엔자, HIV 등) 는 변이가 빠르며, 연간 유전자 위치당 약 10 만분의 1 ~ 1 천분의 1 비율로 변이가 축적됩니다.

**핫스팟 (hotspot)** 이란 변이가 유독 많이 생기는 유전체 위치 또는 영역입니다. 핵심적 구분은:

- **생물학적으로 의미 있는 핫스팟:** 면역 회피, 감염력 증가 등 바이러스에 이점을 주는 변이가 집중 (예: SARS-CoV-2 Spike 484 번 위치 — Beta, Gamma, Mu, Omicron 계통에서 독립적 반복 출현)
- **Founder effect 에 의한 핫스팟:** 빈도가 높지만 “유리해서” 가 아니라 “그 변이를 가진 계통이 우연히 크게 번성해서” 인 경우 (예: D614G)

Table 1: 주요 생물학 용어 정리

| 용어                             | 정의                                                            |
|--------------------------------|---------------------------------------------------------------|
| Mutation (변이)                  | 바이러스 복제 시 발생하는 뉴클레오타이드/아미노산 서열 변화                             |
| Hotspot (핫스팟)                  | 변이가 우연 기대치보다 자주 축적되는 계통 위치                                    |
| Convergent evolution (수렴 진화)   | 서로 관련 없는 계통에서 동일 변이가 독립적으로 출현 — 양성 선택의 증거                     |
| Purifying selection (정화 선택)    | 단백질 구조/기능을 파괴하는 해로운 변이의 진화적 제거                                |
| Founder effect (창시자 효과)        | 특정 변이가 “유리해서” 가 아니라 그 계통이 우연히 크게 번성하여 빈도가 높아진 현상              |
| DMS (Deep Mutational Scanning) | 모든 가능한 아미노산 치환의 기능적 영향을 실험적으로 측정하는 기법                         |
| MSA (다중 서열 정렬)                 | 여러 단백질 서열을 정렬하여 위치별 변이를 식별하는 계산 방법                            |
| Epitope (에피토프)                 | 항체가 결합하는 항원의 특정 부위. 면역 회피 변이는 주로 에피토프에서 발생                    |
| dN/dS                          | 비동의치환율/동의치환율 비율. $>1$ 이면 양성 선택 (변이 유리), $<1$ 이면 정화 선택 (변이 유해) |

| 용어                                     | 정의                                           |
|----------------------------------------|----------------------------------------------|
| MCC (Matthews Correlation Coefficient) | 이진 분류 성능 지표 (-1~+1). 불균형 데이터에서 F1 보다 공정한 평가  |
| ANOVA (분산분석)                           | 성능 차이가 어떤 요인 (방법, 바이러스, 조합) 때문 인지 분리하는 통계 기법 |
| PLM (단백질 언어 모델)                        | 대규모 단백질 서열로 학습된 AI 모델 (ESM-2, Tranception 등) |
| FUBAR                                  | HyPhy 의 베이지안 방법. 각 코돈 위치에서 양성/정화 선택 여부를 추정   |
| pLDDT                                  | AlphaFold 의 구조 예측 신뢰도 (0~100). 낮으면 유연/무질서 영역 |

## 1.2 Research Motivation and Problem Definition (연구 동기)

핫스팟 분석의 궁극적 목적은 백신 설계, 항바이러스제 개발, 실시간 변이 감시에 필요한 “**주의해야 할 위치 목록**” 을 제공하는 것입니다. 이를 위해 다양한 통계적 탐지 방법이 개발되어 왔으나, 현재 세 가지 근본적인 한계에 직면해 있습니다.

**한계 1: 탐지 결과의 생물학적 의미를 평가할 표준 기준이 없습니다.**

통계적 방법으로 “변이가 집중된 위치” 를 찾는 것 자체는 가능합니다. 그러나 찾아낸 위치가 **생물학적으로 의미 있는 핫스팟**인지 판단할 공인된 기준 (ground truth) 이 없습니다. 왜 이 기준을 정하기 어려운가 하면:

- **핫스팟의 정의 자체가 모호합니다.** “변이가 많이 일어나는 곳” 인지, “면역 회피에 중요한 곳” 인지, “기능적으로 중요한 곳” 인지에 따라 답이 달라집니다. 같은 바이러스를 연구하는 두 연구팀이 서로 다른 정의를 사용할 수 있습니다.
- **관찰 시점에 따라 달라집니다.** 2020 년에는 핫스팟이 아니었던 위치가 2022 년 오미크론 출현 후 핵심 핫스팟이 되기도 합니다. 즉 “정답” 이 시간에 따라 변합니다.
- **생물학적으로 의미 있는 핫스팟과 그렇지 않은 핫스팟의 구분이 어렵습니다.** D614G 처럼 빈도가 높은 위치가 자연선택 때문인지 단순히 그 계통이 번성해서인지 (founder effect) 서열 데이터만으로는 구분하기 어렵습니다.
- **최종 검증은 실험실에서만 가능합니다.** 컴퓨터 분석으로 “이 위치가 핫스팟일 가능성이 높다” 까지는 판단할 수 있지만, 그 위치의 변이가 실제로 면역 회피나 감염력 증가를 일으키는지는 Deep Mutational Scanning(DMS) 같은 실험을 통해서만 확인할 수 있습니다. DMS 는 단백질의 모든 가능한 아미노산 치환을 하나씩 만들어 기능적 영향을 측정하는 기법으로, 비용과 시간이 많이 들어 일부 바이러스에서만 수행되었습니다.

따라서 각 논문이 자기 기준으로 “잘 찾았다” 고 주장하지만, 기준이 다르니 비교할 수 없습니다. 본 연구에서는 이 문제를 해결하기 위해 수렴 진화 (Layer A), 정화 선택 (Layer B), DMS 데이터 (Layer C) 라는 세 가지 독립적 근거를 결합한 3 층 정답 기준을 설계했습니다.

**한계 2: 방법 간 공정한 비교와 일반화 검증이 되지 않았습니다.**

- **평가 조건이 통일되지 않았습니다.** 방법 A 는 코로나 데이터 5,000 개 서열로, 방법 B 는 인플루엔자 데이터 2,000 개 서열로 각각 테스트했습니다. 서로 다른 바이러스, 서로 다른 서열 수, 서로 다른 평가 기준을 사용했으므로 어떤 방법이 더 나은지 비교할 수 없습니다.
- **단일 바이러스 결과를 일반화할 수 없습니다.** 코로나에서 우수한 방법이 HIV 에서도 유효한지, 노로바이러스에서도 적용 가능한지 검증된 적이 없습니다. 바이러스마다 변이 속도 (HIV 는 코로나의 10 배), 게놈 크기 (HCV 340AA vs MERS 1,330AA), 진화 패턴 (H3N2 의 지속적 변이 vs Norovirus 의 에포크형 변이) 이 달라, 하나의 바이러스 결과가 다른 바이러스에 적용된다는 보장이 없습니다.
- **복합적 평가 지표가 없습니다.** 기존 연구들은 precision 이나 recall 같은 단일 지표로만 보고하여, “정밀하지만 많이 놓치는 방법” 과 “많이 찾지만 위양성 (false positive) 이 많은 방법” 중 어느 것이 나은지 판단할 기준이 없습니다.

**한계 3: 정보 유형 간 기여도 분석이 없습니다.**

핫스팟 탐지에 사용할 수 있는 정보는 빈도, 엔트로피, 계통발생 신호 (dN/dS, FUBAR), 구조 정보 (pLDDT, SASA), AI 예측 (ESM-2, Tranception) 등 다양합니다. 그러나 이들 중 어떤 정보가 핫스팟 탐지에 가장 핵심적인지, 정보 유형 간 기여도를 체계적으로 비교한 연구가 없습니다.

### 1.3 Research Objectives (연구 목표)

위 세 가지 한계를 해결하기 위해 본 연구는 다음 세 가지 목표를 설정합니다.

#### 목표 1: 다양한 정보 유형을 체계적으로 비교할 수 있는 실험 프레임워크 (MutBench) 구축

- **필요성:** 빈도/엔트로피 외에도 계통 분석, 구조 정보, AI 예측 등 다양한 정보가 존재하지만, 이들을 동일 조건에서 비교할 표준화된 정답 기준과 실험 설계가 없었습니다.
- **방법:** (1) 3 층 정답 기준 (수렴 진화·보존 영역·DMS) 을 설계하고, (2) 11 개 바이러스 × 20 점수화 유형 (6 개 카테고리) × 14 탐지 패밀리 (5 개 카테고리, 39 변형) = **8,580 회** 평가를 수행합니다.
- **기대 결과:** 다양한 정보 유형과 탐지 방법을 동일 조건에서 비교할 수 있는 표준화된 실험 기반을 제공합니다.

#### 목표 2: 핫스팟 탐지 성능의 핵심 요인 규명

- **필요성:** 10 가지 정보 유형과 14 개 탐지 방법 중 어떤 요인이 성능에 가장 큰 영향을 미치는지 정량적으로 분해해야, 연구 자원의 우선순위를 정할 수 있습니다.
- **방법:** 성능 차이가 어디서 생기는지 나누어 봅니다. “점수를 매기는 정보가 중요한가?”, “탐지 알고리즘이 중요한가?”, “바이러스 종류가 중요한가?”, “특정 정보가 특정 바이러스에서만 잘 맞는가?” 를 통계적으로 분리합니다.
- **기대 결과:** 가장 큰 차이는 “정보 유형과 바이러스의 궁합” 에서 나왔습니다. 숫자로는 정보 유형 × 바이러스 효과가 가장 큰 요인 ( $\omega^2=0.296$ ) 이었고, HIV-1 에서는 실제 백신 회피 위치가 무작위보다 7.19 배 더 잘 모였습니다. 즉 단순히 점수가 좋은 알고리즘을 고르는 문제가 아니라, 바이러스에 맞는 정보를 고르는 문제입니다.

#### 목표 3: 바이러스별 핵심 정보 식별 및 실험 탐색 범위 축소 검증

- **필요성:** 10 가지 정보 유형 중 어떤 것이 핵심이고, 이를 통합하면 실험 탐색 범위를 얼마나 줄일 수 있는지 정량화해야 합니다.
- **방법:** (1) Per-feature AUC 와 Random Forest 로 바이러스별 핵심 정보 유형을 식별하고, (2) Feature ablation 으로 최소 필수 정보 조합을 규명하며, (3) Vaccine escape enrichment 분석으로 벤치마크 결과가 실제 면역 회피 위치와 일치하는지 독립 검증합니다.
- **기대 결과:** 많은 정보를 다 쓰지 않아도 핵심 정보 4 개 (homoplasy, pLDDT, entropy, freq) 만으로 대부분의 성능을 유지했습니다. 다만 외부 검증으로 가장 깨끗하게 말할 수 있는 사례는 HIV-1 이며, H3N2 와 SARS-CoV-2 결과는 각각 자기 일관성 확인 또는 탐색적 결과로 조심스럽게 해석합니다.

## Chapter 2. Related Research (관련 연구)

### 2.1 Viral Mutation Hotspot Detection (바이러스 변이 핫스팟 탐지)

**2.1.1 핫스팟 탐지의 3 단계와 각 단계의 방법론** 핫스팟 탐지는 세 단계로 이루어지며, 각 단계에서 사용되는 방법론이 다릅니다.

#### 1 단계: 서열 수집 및 정렬

전 세계 연구기관에서 바이러스 유전자 서열을 수집 (GISAID, NCBI GenBank) 하고, 다중 서열 정렬 (MSA) 을 수행합니다. 이 단계에서 각 위치별로 “어떤 변이가 얼마나 발생했는가” 를 비교할 수 있는 기반이 만들어집니다.

#### 2 단계-A: 점수화 (Scoring) — 각 위치에 “얼마나 중요한가” 점수 부여

MSA 의 각 아미노산 위치에 대해, 다양한 생물학적 정보를 활용하여 점수를 계산합니다. 본 연구에서는 6 개 카테고리, 20 가지 점수화 유형을 비교합니다.

- **빈도 기반** (3 가지: freq, rare\_freq, freq\_with\_indel)
  - 변이 빈도를 직접 계산합니다. 가장 직관적이나 계통 편향 (founder effect) 에 취약합니다.
  - 입력: MSA 만 필요 (추가 데이터 없음)
- **MSA 유래** (3 가지: entropy, entropy\_with\_indel, homoplasy)
  - Shannon 엔트로피로 다양성을, homoplasy 로 수렴 변이 (독립 발생 횟수) 를 측정합니다.
  - 입력: MSA + 계통수 (homoplasy 의 경우)
- **계통 분석 기반** (4 가지: dN/dS proxy, FUBAR×3)
  - 코돈 (3 개 염기로 1 개 아미노산을 지정하는 단위) 수준에서 양성선택 압력을 추정합니다. 빈도와 달리 자연선택 신호를 직접 측정합니다.
  - 입력: 코돈 정렬 + 계통수. 트리 품질에 의존합니다.
- **구조 기반** (3 가지: pLDDT, SASA, Grantham)
  - 3D 구조 신뢰도, 표면 노출도, 아미노산 물리화학적 거리를 측정합니다.
  - 입력: AlphaFold/ESMFold 예측 구조. 구조 예측 정확도에 의존합니다.
- **AI 기반** (5 가지: ESM-2 LLR, Tranception, semantic change, stability×2)
  - 단백질 언어모델이 학습한 진화적 제약을 기반으로 변이 허용도를 예측합니다.
  - 입력: 단백질 서열 + GPU. 학습 데이터에 바이러스가 과소대표되어 있을 수 있습니다.
- **복합** (2 가지: EVEscape composite, EqualWeight)
  - 위 여러 정보를 결합합니다.

#### 2 단계-B: 탐지 (Detection) — 점수 프로파일에서 핫스팟 영역 식별

점수화된 1 차원 배열에서 “높은 영역” 을 찾아 핫스팟으로 지정합니다. 본 연구에서는 5 개 카테고리, 14 개 패밀리 (39 변형) 를 비교합니다.

- **밀도 기반**: DBSCAN, HDBSCAN, KDE, MutClust
- **임계값 기반**: FreqThresh (상위 N%), AdaptiveKnee, AdaptWin
- **신호 처리**: Wavelet 변환, Spectral 필터, CUSUM 변화점 탐지
- **통계 검정**: Sliding window t-test, Bayesian change-point, GradPeak, LocalContrast
- **적응 윈도우**: SWAN (윈도우 크기 자동 조정)

모든 탐지 방법은 동일한 1 차원 점수 배열을 입력으로 받습니다.

본 연구에서는 20 가지 점수화 × 14 개 탐지 패밀리 (39 변형) × 11 개 바이러스 = **8,580 회** 평가를 수행합니다.

#### 3 단계: 실험 검증 — DMS(Deep Mutational Scanning) 를 활용한 독립 검증

식별된 핫스팟이 생물학적으로 의미 있는지는 궁극적으로 실험실에서 검증해야 합니다. DMS 는 단백질의 **모든 가능한 아미노산 치환**을 체계적으로 생성하고, 각 치환의 기능적 영향 (결합력, 세포 침입, 복제 효율) 을 정량 측정하는 실험으로, 가장 직접적인 실험적 정답 기준입니다.

- **왜 정답 기준인가**: 편향 없이 포괄적이며 실험적 (계산 예측이 아닌 직접 측정)

- **주요 DMS 연구:** Starr 2020 (SARS-CoV-2 RBD), Dadonaite 2024 (전체 Spike), Lee 2018 (H3N2 HA)
- **한계:** 비용이 높고, pseudovirus 사용 (실제 바이러스와 차이 가능), in vitro ≠ in vivo
- **가용성 격차:** EVEREST 45 개 DMS 포함, WHO 우선순위 바이러스 절반 이상에서 DMS 부재. 본 연구에서는 6 개 병원체의 DMS 를 Layer C 독립 검증으로 활용

**2.1.2 선행 연구와 본 연구의 차이** 지금까지 살펴본 정보 유형 (빈도, 엔트로피, 계통, PLM, 구조) 을 개별적으로 활용한 연구는 있지만, **이들을 체계적으로 비교한 연구는 없습니다.**

**“예측 벤치마크”와 “탐지 벤치마크”의 차이:**

변이 효과 **예측** (VEP) 과 핫스팟 **탐지**는 근본적으로 다른 문제입니다:

- **예측** (EVEREST, ProteinGym): “484 번 위치의 K→E 변이가 감염력을 얼마나 바꾸는가?” — 개별 변이 하나하나의 효과를 점수로 평가합니다. 평가 기준은 DMS 실험값과의 상관 (Spearman) 입니다.
- **탐지** (MutBench): “Spike 단백질에서 변이가 집중되는 영역이 어디인가?” — 변이가 몰리는 게놈 구간을 찾아 실험 검증의 우선순위를 제공합니다. 평가 기준은 정답 위치와의 이진 분류 정확도 (MCC) 입니다.

예측은 “각 학생의 시험 점수를 예측” 하는 것이고, 탐지는 “성적이 낮은 학생이 몰려있는 반을 찾는” 것입니다. 두 문제는 상보적이지만 방법론과 평가 기준이 다르므로 직접 비교할 수 없습니다.

Table 2: 관련 연구와 MutBench 의 비교

| 연구                                                                    | 무엇을 하나                                                                                       | MutBench 와의 차이                                                                                                                                              |
|-----------------------------------------------------------------------|----------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>ViroGym</b><br>(arXiv, 2026 Mar)                                   | 13 바이러스, 79 DMS, 552k 서열, 7 phenotype(면역 회피 포함). ESM-1/1v/2, ProGen2, Tranception 등 PLM 벤치마크 | 변이 효과 <b>예측</b> 벤치마크. MutBench 와 task 가 다름 (per-variant fitness vs per-region detection). 바이러스 수는 ViroGym 이 더 많음 → “broadest” 표현은 hotspot detection 한정으로 사용 |
| <b>EVEREST v3</b><br>(bioRxiv, 2026 Jan)                              | 45 바이러스 DMS + 31 클레이드 forecasting + WHO 우선 40 바이러스 reliability. 절반 이상에서 신뢰도 실패 보고            | per-variant 예측 벤치마크. WHO-40 reliability 실패는 본 연구 LOPO 0/11 결과를 외부 corroboration                                                                             |
| <b>PLANT</b><br>(bioRxiv, 2025) / <b>Wu et al.</b> (Nat Commun, 2024) | PLM·ML 기반 H3N2 항원 cartography. WHO 백신주 선정과 경쟁                                                | H3N2 예측 측. MutBench 의 H3N2 self-consistency check 와 task 보완 관계                                                                                              |
| <b>ProteinGym v1.3</b> (2025 Apr)                                     | 217 DMS, <b>90 개 이상</b> 예측 모델 (ProGen3, ESM3/C, xtrimoPGLM 포함; v1 은 70 개)                    | per-mutation 예측. 핫스팟 영역 탐지가 아님                                                                                                                              |
| <b>EVEscape</b><br>(Nature, 2023)                                     | 바이러스 escape 변이 사전 예측. 적합도 + 접근성 + 비유사도 결합                                                    | 단일 예측 모델이지 탐지 비교 벤치마크가 아님                                                                                                                                   |
| <b>CoVFit</b> (Nat Commun, 2025)                                      | SARS-CoV-2 spike fitness PLM (ESM-2 fine-tune)                                               | SARS-CoV-2 한정. MutBench 의 “SARS-CoV-2 = Tranception 최적” 발견을 외부 보강                                                                                           |
| <b>AlphaMissense</b><br>(Cheng 2023)                                  | proteome-wide variant 분류. 인간 단백질 중심                                                          | 바이러스 전이성 미검증, MutBench 비교 표 2.2 에 칼럼으로 등록                                                                                                                   |

| 연구                                                                                                                                           | 무엇을 하나                                                | MutBench 와의 차이                           |
|----------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------|------------------------------------------|
| <b>Hie et al.</b><br>(Science, 2021),<br><b>Maher et al.</b><br>(Sci Transl<br>Med, 2022),<br><b>Obermeyer et<br/>al.</b> (Science,<br>2022) | escape 예측 / SARS-CoV-2 변이<br>주 feature / 640 만 게놈 적합도 | 모두 단일 바이러스 또는 단일 방법; 다중-바이러스<br>탐지 비교 아님 |
| <b>ConDor</b> (2024)                                                                                                                         | 계통수에서 수렴 변이 탐지                                        | 단일 탐지 도구; 벤치마크 프레임워크가 아님                 |

### EVEREST v3 / ViroGym vs MutBench — 가장 유사하지만 근본적으로 다른 연구

EVEREST v3(Marks lab, 2026 Jan) 와 ViroGym(2026 Mar) 는 MutBench 와 가장 가까운 연구이며, “최적 방법이 바이러스마다 다르다” 는 결론도 동일합니다. 그러나 두 연구가 답하는 질문이 근본적으로 다릅니다 (ViroGym/EVEREST = per-variant fitness 예측, MutBench = per-region 탐지):

Table 3: EVEREST vs MutBench 핵심 차이

| 비교 항목     | ViroGym / EVEREST v3                                            | MutBench                                                |
|-----------|-----------------------------------------------------------------|---------------------------------------------------------|
| 답하는 질문    | “이 변이가 바이러스 적합도에 어떤 영향을 미치는가?”<br>(per-mutation 예측)             | “게놈의 어떤 영역에 변이가 집중 되는가?” (per-region 탐지)                |
| 평가 단위     | 개별 변이 (A484K 같은 단일 치환)                                          | 게놈 위치/영역 (484 번 위치 주변 클러스터)                             |
| 정답 기준     | DMS 적합도 점수 (연속값, Spearman 상관)                                   | 3 층 정답 기준 (Layer A 이진 분류, MCC)                          |
| 입력 정보     | 고정 (정렬 기반 or PLM — 방법 자체를 비교)                                   | <b>다양한 정보 유형을 비교</b> (빈도, 계통, 구조, AI 등 20 가지)           |
| 핵심 발견     | EVEREST v3: 여러 바이러스에서 예측 신뢰도 한계.<br>ViroGym: 바이러스가 바뀌면 일반화가 어려움 | <b>바이러스마다 잘 맞는 정보가 다르다</b> (정량 근거: $\omega^2=0.296$ )   |
| 실용적 검증    | 없음                                                              | HIV-1 백신 회피 위치를 무작위보다 7.19 배 잘 모아 찾음. H3N2 는 보조 확인으로 해석 |
| DMS 필요 여부 | 필수                                                              | 선택적 (Layer C 보조 검증, DMS 없이도 Layer A 로 평가 가능)            |
| 바이러스 수    | ViroGym 13, EVEREST v3 4 forecasting + 40 reliability           | 11 (그러나 task 가 hotspot detection 으로 다름)                 |

핵심 차이: ViroGym/EVEREST v3 는 “어떤 예측 모델이 좋은가” 를, MutBench 는 “어떤 정보가 어떤 바이러스에 유효한가” 를 분석합니다. 두 분야 모두 바이러스가 바뀌면 성능이 흔들린다는 비슷한 패턴을 보입니다.

Table 4: 기존 접근과 MutBench 비교

| 특성       | MutClust | Bailey 2018 (암) | MOSD (다중오믹스)  | <b>MutBench</b>      |
|----------|----------|-----------------|---------------|----------------------|
| 도메인      | 바이러스     | 암               | 다중오믹스         | <b>바이러스</b>          |
| 독립 정답 기준 | 없음       | 있음              | 있음            | <b>있음 (3 층)</b>      |
| 복합 평가 지표 | 없음       | 없음              | cluster-score | <b>hotspot-score</b> |

| 특성        | MutClust | Bailey 2018 (암) | MOSD (다중오믹스) | MutBench                  |
|-----------|----------|-----------------|--------------|---------------------------|
| 다중 병원체 비교 | 부분 (2 개) | 해당 없음           | 해당 없음        | 있음 (11 개)                 |
| 통계적 방법 선택 | 없음       | 없음              | ANOVA        | ANOVA+Friedman+LOPO       |
| 비교 방법 수   | 1 개      | 26 개            | 10 개         | 14 families (39 variants) |

## Chapter 3. Materials and Methods (재료 및 방법)

### 3.1 Materials (재료)

**3.1.1 Target Pathogens and Data (11 개 바이러스)** 다양한 진화 양상을 포괄하기 위해 11 개 RNA 바이러스의 표면 단백질을 분석 대상으로 선정했습니다.

**핵심 고려사항 1:** 왜 전체 게놈이 아닌 표면 단백질만 분석하는가?

바이러스 게놈에는 복제 효소 (RdRp), 프로테아제, 비구조 단백질 등 다양한 유전자가 있지만, 핫스팟 탐지의 실용적 목적 (백신 설계, 항체 치료제, 면역 회피 감시) 은 **면역계가 직접 인식하는 단백질**에 집중됩니다. 표면 단백질을 선택한 구체적 이유:

1. **숙주 세포 진입 매개:** 표면 단백질은 수용체 (ACE2, CD4, 시알산 등) 에 결합하여 감염을 시작하므로, 이 단백질의 변이가 감염력에 직접 영향
2. **중화 항체의 주요 표적:** 면역계가 바이러스를 인식하고 중화하는 곳이 표면 단백질이므로, 면역 회피 변이는 여기서 발생
3. **백신 설계의 핵심 항원:** 현재 사용 중인 백신 (mRNA, 단백질 서브유닛) 은 모두 표면 단백질을 항원으로 사용
4. **양성 선택 (positive selection) 집중:** 면역 압력을 직접 받는 표면 단백질에서 적응 진화가 가장 활발
5. **DMS 데이터 가용성:** 비용이 큰 DMS 실험은 대부분 표면 단백질에서만 수행됨

비구조 단백질 (예: SARS-CoV-2 NSP1-16) 의 변이는 주로 정화 선택 하에 있으며, 면역 회피와 무관하여 Layer A(수렴 진화) 정답 정의가 불가능합니다.

참고: Norovirus(VP1) 와 EV-A71(VP1) 은 외피막 (envelope) 이 없는 바이러스이므로 “표면 단백질” 이라기 보다 **캡시드 표면 단백질**이 정확합니다. 그러나 중화 항체 표적이라는 기능적 역할은 동일합니다.

**전파 경로별 분류:**

- 호흡기: SARS-CoV-2, MERS, RSV, H3N2, Influenza B
- 혈액/성매개: HIV-1, HCV
- 위장관: Norovirus
- 모기 매개: Dengue
- 신경 친화성: Rabies, EV-A71

Table 5: 11 개 바이러스 서열 데이터

| 바이러스        | 표면 단백질    | 서열 수  | 고유 서열 | 길이 (AA) |
|-------------|-----------|-------|-------|---------|
| SARS-CoV-2  | Spike     | 4,982 | 753   | 1,259   |
| H3N2        | HA        | 2,644 | 2,562 | 543     |
| Norovirus   | VP1       | 1,500 | 791   | 536     |
| HIV-1       | Env gp120 | 3,000 | 2,256 | 450     |
| Dengue      | E protein | 2,000 | 796   | 490     |
| RSV         | F protein | 5,070 | 4,779 | 550     |
| Influenza B | HA        | 5,325 | 5,019 | 560     |
| MERS        | Spike     | 1,311 | 530   | 1,330   |
| HCV         | E2        | 1,362 | 1,067 | 340     |
| Rabies      | G protein | 2,038 | 2,038 | 491     |
| EV-A71      | VP1       | 662   | 662   | 261     |

Table 6: 11 개 바이러스 진화 특성

| 바이러스       | 단백질 기능         | 변이 속도          | 진화 패턴           |
|------------|----------------|----------------|-----------------|
| SARS-CoV-2 | ACE2 결합, 세포 진입 | $\sim 10^{-3}$ | 수렴 진화 (E484K/A) |



| 바이러스        | 단백질 기능        | 변이 속도                     | 진화 패턴             |
|-------------|---------------|---------------------------|-------------------|
| H3N2        | 시알산 결합, 항원 변이 | $\sim 4 \times 10^{-3}$   | 지속적 항원 표류         |
| Norovirus   | HBGA 결합, 캡시드  | $\sim 2 \times 10^{-3}$   | 에포크형 (2-4 년)      |
| HIV-1       | CD4 결합        | $\sim 2.5 \times 10^{-3}$ | 환자 내 다양화          |
| Dengue      | 수용체 결합, 막 융합  | $\sim 7.6 \times 10^{-4}$ | 4 혈청형 분화          |
| RSV         | 세포막 융합        | $\sim 1.5 \times 10^{-3}$ | 중간 속도 변이          |
| Influenza B | 수용체 결합        | $\sim 2 \times 10^{-3}$   | Victoria/Yamagata |
| MERS        | DPP4 결합       | $\sim 9 \times 10^{-4}$   | 산발적 인수공통          |
| HCV         | CD81 결합       | $\sim 10^{-3}$            | 초변이 (HVR1)        |
| Rabies      | nAChR 결합      | $\sim 4 \times 10^{-4}$   | 강한 정화 선택          |
| EV-A71      | 중화 에피토프       | $\sim 4.5 \times 10^{-3}$ | 유전형 교체            |

이 11 종은 변이 속도 ( $\text{HIV-1} \sim 10^{-3} \sim \text{Rabies} \sim 4 \times 10^{-4}$ ), 단백질 길이 ( $\text{EV-A71}$  261 AA  $\sim$   $\text{MERS}$  1,330 AA, post-truncation), 진화 패턴 ( $\text{H3N2}$  지속적 변이 vs  $\text{Norovirus}$  에포크형) 이 모두 달라, 단일 바이러스에 치우치지 않는 평가를 보장합니다.

#### 핵심 고려사항 2: 왜 이 11 개 바이러스인가?

벤치마크에 포함할 병원체를 선정할 때 세 가지 기준을 적용했습니다. 첫째, ANOVA 나 Friedman 검정의 통계적 검정력을 확보하기 위해 **모든 병원체에서 530 개 이상의 고유 서열이** 필요합니다. 둘째, 쉬운 병원체 ( $\text{HCV}$ , Oracle MCC 0.660) 부터 매우 어려운 병원체 ( $\text{MERS}$ , 0.196) 까지 **난이도가 다양해야** 벤치마크 결과가 특정 난이도에 편향되지 않습니다. 셋째, H-score 기반 점수화가 의미 있으려면 변이가 충분히 축적되어야 하므로, 변이율이  $10^{-6} \sim 10^{-8}$  인 **DNA 바이러스는 제외**하고 RNA 바이러스 ( $10^{-3} \sim 10^{-4}$ ) 로 한정했습니다.

#### 데이터 수집 및 전처리:

NCBI GenBank 에서 각 표면 단백질의 완전한 코딩 서열을 수집하였습니다. 모호한 염기 (N) 가 5% 이상인 서열 제거, 동일 서열 중복 제거 후 MAFFT v7.505 로 다중 서열 정렬 (MSA) 을 수행했습니다. MSA 를 통해 “484 번 위치에서 어떤 아미노산이 몇 번 관찰되었는가” 를 비교할 수 있게 됩니다. 이후 위치별 변이 빈도와 Shannon 엔트로피를 계산합니다.

Figure 1 은 11 개 병원체의 데이터 특성을 4 개 패널로 요약합니다.

### 3.2 Methods (방법)

**3.2.1 Framework Overview (프레임워크 개요)** MutBench 는 다음 5 단계 파이프라인으로 구성됩니다.

1. **입력:** 11 개 병원체의 MSA(다중 서열 정렬) 데이터
2. **정답 구축:** 3 층 Ground Truth (Layer A: 수렴 진화, Layer B: 보존 영역, Layer C: DMS 실험)
3. **점수화:** 각 위치에 점수 부여 — 6 개 카테고리, 20 가지 유형 (빈도, 엔트로피, FUBAR, pLDDT, ESM-2 등)
4. **탐지:** 점수 프로파일에서 핫스팟 영역 판별 — 14 개 알고리즘 패밀리, 39 개 변형
5. **평가:** 정답 대비 성능 측정 (MCC, Constrained FPR, DMS F1) + 통계 분석 (3-way ANOVA, Friedman, LOPO)

평가는 2 단계 (Stage) 로 구성됩니다:

|              | Stage 1            | Stage 2               |
|--------------|--------------------|-----------------------|
| <b>대상</b>    | SARS-CoV-2 1 개     | 11 개 바이러스 전체          |
| <b>목적</b>    | 평가 도구 자체가 작동하는지 검증 | 핵심 질문 — “만능 방법이 있는가?” |
| <b>규모</b>    | 5 개 세부 실험          | 8,580 회 대규모 평가        |
| <b>핵심 지표</b> | hotspot-score      | MCC                   |

## 11 Pathogens: Data Characteristics Overview




Figure 1: 11 개 병원체 데이터 특성 개요. (A) 단백질 길이 — EV-A71(261 AA) 부터 MERS(1,330 AA) 까지 5.1 배 차이. (B) 고유 서열 수 — MERS(530) 부터 Influenza B(5,019) 까지 9.5 배 차이. (C) 3 층 정답 위치 수 — Layer A(파랑), B(초록), C(주황). DMS(Layer C) 는 6/11 에서만 가용. (D) 전파 경로와 진화 패턴.

### 핵심 고려사항 3: 왜 실험을 2 단계 (Stage) 로 나누었나?

한 번에 11 개 바이러스로 실험하면, 결과가 나쁠 때 “탐지 방법이 나쁜 건지, 평가 도구가 나쁜 건지” 구분할 수 없습니다. 그래서 먼저 Stage 1 에서 가장 데이터가 풍부한 SARS-CoV-2 로 평가 도구의 신뢰성을 검증한 뒤, Stage 2 에서 검증된 도구로 본격적인 교차 비교를 수행합니다.

### 3.2.2 3-Layer Ground Truth Framework (3 층 정답 기준) 핫스팟 탐지 방법의 성능을 공정하게 비교하려면, “어떤 위치가 진짜 핫스팟인지” 를 정의한 정답표 (ground truth) 가 필요합니다.

기존 탐지 방법들은 서열 데이터에서 변이가 집중된 위치를 찾아내는 것 자체는 가능합니다. 문제는 찾아낸 위치가 생물학적으로 유의미한지 판단할 기준이 없다는 것입니다. 빈도가 높다고 해서 반드시 면역 회피나 기능 변화와 관련된 것은 아닙니다 — founder effect 로 인해 빈도만 높을 수도 있고, 중립적인 변이가 축적된 것일 수도 있습니다.

따라서 MutBench 의 정답표는 단순히 “변이가 많은 곳” 이 아니라, “생물학적으로 중요한 핫스팟이라고 확인 된 곳” 을 기준으로 합니다. 탐지 방법이 찾아낸 위치가 이 정답표와 얼마나 일치하는지를 측정하여, “단순히 빈도 높은 곳을 찾는 것” 이 아닌 “생물학적으로 의미 있는 위치를 정확히 찾는 것” 을 평가합니다.

본 연구에서는 세 가지 서로 독립적인 생물학적 근거를 결합하여 이 정답표를 구성했습니다. 세 근거는 각각 “생물학적으로 의미 있는 핫스팟”, “핫스팟으로 잘못 판정하면 특히 위험한 곳”, “실험실에서 직접 기능 영향을 측정한 곳” 이라는 서로 다른 역할을 담당합니다.

#### Layer A — “자연선택이 반복적으로 작용한 위치”

**생물학적 의미:** 같은 바이러스 종 안에서 서로 다른 계통 (lineage) 이 독립적으로 같은 위치에서 변이한 곳입니다. 이것을 수렴 진화 (convergent evolution) 라 합니다.

예를 들어 SARS-CoV-2 Spike 484 번 위치의 변이는 Beta(남아공)·Gamma(브라질)·Mu(콜롬비아) 계통에서 E484K(글루탐산 → 라이신) 로, Omicron(남아공) 계통에서 E484A(글루탐산 → 알라닌) 로 각각 독립적으로

출현했습니다. 서로 관련 없는 계통에서 같은 변이가 반복된다는 것은, 해당 변이가 바이러스에게 **생존 이점** (면역 회피, 수용체 결합력 증가, 복제 효율 향상 등) 을 제공한다는 강력한 증거입니다. 이러한 위치를  $\geq 3$  개 독립 계통에서 반복 출현이 문헌에 보고된 것을 기준으로 선정했습니다.

**벤치마크에서의 역할:** 탐지 방법이 찾아야 할 **양성 기준 (True Positive)** 입니다. “이 위치를 찾았는가?” 로 recall(재현율) 을 계산합니다. 병원체당 9~54 개 위치.

#### Layer B — “변이하면 바이러스가 죽는, 구조적으로 필수적인 위치”

**생물학적 의미:** 단백질이 정상적으로 기능하기 위해 반드시 보존되어야 하는 구조적 핵심 부위입니다. 이 위치에서 변이가 일어나면 단백질의 3D 구조가 무너지거나 기능을 잃어, 바이러스 자체가 생존할 수 없습니다. 이를 **정화 선택 (purifying selection)** 하에 있다고 합니다.

예를 들어 Spike 단백질의 heptad repeat(HR1/HR2) 영역은 세포막 융합에 필수적인 구조로, 여기서 변이가 일어나면 바이러스가 세포에 진입 자체를 못합니다.

**벤치마크에서의 역할:** 탐지 방법이 이곳을 핫스팟이라고 **잘못 판정하는지 감시**합니다. 핵심 지표 (MCC) 에는 직접 사용하지 않고, 별도 보조 지표 (Constrained FPR) 로 측정합니다. “여기를 핫스팟이라 하면 백신/약물 타겟을 잘못 설정하는 위험” 을 모니터링합니다. 병원체당 0~229 개 위치.

#### Layer C — “실험실에서 측정한 각 위치의 기능적 영향”

**생물학적 의미:** Deep Mutational Scanning(DMS) 실험에서 단백질의 모든 가능한 아미노산 치환을 물리적으로 만들어, 각 치환이 바이러스 기능에 미치는 영향을 직접 측정한 결과입니다. 예를 들어 SARS-CoV-2 Spike 단백질에서 각 위치의 변이가 세포 진입 효율을 높이는지 낮추는지를 정량적으로 보여줍니다.

Layer A 와 B 가 진화 패턴이나 구조 정보에 기반하는 반면, Layer C 는 **실험실에서 직접 확인한 “생물학적 사실”** 입니다. 어떤 위치는 실험적으로 강한 기능적 영향을 보이지만 아직 자연에서 수렴 진화가 관찰되지 않았을 수 있으므로, Layer A 와는 독립적인 검증 근거를 제공합니다.

**벤치마크에서의 역할:** Layer A/B 와 독립적인 **실험적 교차 검증**입니다. 탐지 방법이 찾은 핫스팟이 실험적으로 확인된 기능적 부위와 일치하는지 확인합니다. 11 개 바이러스 중 DMS 데이터가 있는 6 개에서만 사용 가능합니다.

Table 8: 3 층 정답 기준 요약

| Layer | 생물학적 의미                   | 벤치마크 역할                    |
|-------|---------------------------|----------------------------|
| A     | 자연선택이 반복 작용한 위치 (수렴 진화)   | 양성 기준 — “이것을 찾았는가?”        |
| B     | 변이하면 바이러스가 죽는 위치 (정화 선택)  | 위험 감시 — “이것을 핫스팟이라 하면 안 됨” |
| C     | 실험실에서 기능 영향이 확인된 위치 (DMS) | 교차 검증 — “실험 결과와 일치하는가?”    |

이 3 층 구조의 핵심은 서로 다른 생물학적 근거를 독립적으로 사용한다는 점입니다. Layer A 는 진화 패턴, Layer B 는 구조적 제약, Layer C 는 실험실 측정으로, 각각 다른 관점에서 “생물학적으로 의미 있는 위치인가” 를 판단합니다.

세 층은 서로 거의 겹치지 않습니다 (Jaccard 유사도 0.006 — 두 집합의 교집합/합집합 비율로, 0 이면 완전 독립, 1 이면 완전 동일). 이는 각 층이 서로 다른 관점에서 독립적인 정보를 제공한다는 것을 의미하며, 단일 기준에 의존하지 않는 균형 잡힌 평가를 가능하게 합니다.

Figure 2 는 11 개 병원체의 Layer A/B/C 정답 위치를 단백질 서열 위에 매핑한 그림입니다.

Table 9: 병원체별 3 층 정답 위치 수

| 바이러스       | Layer A | Layer B | Layer C | Layer A 출처                    |
|------------|---------|---------|---------|-------------------------------|
| SARS-CoV-2 | 25      | 154     | 252     | Carabelli 2023, Cao 2023      |
| H3N2       | 25      | 10      | 102     | Koel 2013 (antigenic cluster) |
| Norovirus  | 15      | 229     | —       | Lindesmith 2012, 2013         |

| 바이러스        | Layer A | Layer B | Layer C | Layer A 출처                    |
|-------------|---------|---------|---------|-------------------------------|
| HIV-1       | 23      | 23      | 100     | Moore & Williamson 2015       |
| Dengue      | 24      | 24      | —       | Twiddy 2002, Holmes 2003      |
| RSV         | 20      | 18      | 101     | Mas 2018, Sullender 2000      |
| Influenza B | 17      | 10      | —       | Ni 2013, Wang 2008            |
| MERS        | 9       | 110     | —       | Kim 2016, Tang 2014           |
| HCV         | 54      | 0†      | —       | HVR1/HVR2 초변이 영역              |
| Rabies      | 39      | 42      | 87      | Benmansour 1991, Aditham 2025 |
| EV-A71      | 27      | 29      | 55      | Huang 2015, Bakhache 2025     |

† HCV 의 CD81 결합 부위 (AA 418-535) 가 정렬 길이 (340 AA) 를 초과하여 유효 Layer B = 0.

DMS Layer C 가용 병원체 6 개: SARS-CoV-2 (Dadonaite 2024), H3N2 (Lee 2018), HIV-1 (Haddox 2018), RSV (Bloom lab 2026), Rabies (Aditham 2025), EV-A71 (Bakhache 2025).

**핵심 고려사항 4:** Layer B/C 가 없는 바이러스는 왜 포함했는가?

11 개 바이러스 중 완전한 3 층 GT(A+B+C) 를 가진 것은 6 개 (SARS-CoV-2, H3N2, HIV-1, RSV, Rabies, EV-A71) 입니다. Norovirus, Dengue, Influenza B, MERS, HCV 는 Layer C(DMS) 가 없습니다. 그럼에도 포함한 이유:

1. **핵심 평가 지표 (MCC) 는 Layer A 만으로 계산됩니다.** Layer A = 정답 (양성), 나머지 전체 = 오답 (음성) 으로 MCC 를 계산하므로, Layer B/C 가 없어도 핵심 평가는 가능합니다. Layer B 는 “특히 나쁜 오답” 을 추가로 측정하는 보조 지표 (Constrained FPR) 에 사용되고, Layer C 는 독립적 검증 (DMS F1) 에 사용됩니다.
2. **6 개만으로는 통계 검정력이 부족합니다.** “만능 방법이 없다” 를 증명하려면 ANOVA, Friedman, LOPO 같은 통계 검정이 필요한데, 6 개 바이러스로는 검정력이 부족합니다. 11 개로 늘려야 통계적으로 유의한 결론을 낼 수 있습니다.
3. **다양성이 완전성보다 중요합니다.** DMS 데이터가 있는 바이러스만 쓰면 잘 연구된 병원체에 편향됩니다. Norovirus(epoch 진화), HCV(초변이), MERS(데이터 부족) 같은 도전적 사례를 포함해야 벤치마크의 현실적 가치가 있습니다.

### Layer A/B 중복 처리

RSV(위치 148, 152) 와 Influenza B(위치 141, 194) 에서는 Layer A 와 B 가 겹치는 위치가 있습니다. 이런 위치는 면역 회피 압력 (양성 선택) 과 구조적 제약 (정확 선택) 을 동시에 받는 이중 선택 부위입니다. MCC 평가에서는 Layer A(양성) 로 우선 처리하고 Layer B(음성) 에서 제외합니다. 따라서 유효 Layer B 는 RSV: 16 개 (18-2), Influenza B: 8 개 (10-2) 입니다.

**3.2.3 Stage 1: SARS-CoV-2 심층 분석** Stage 1 은 SARS-CoV-2 를 기준 병원체로 사용하여 프레임워크의 세 가지 핵심 요소를 검증합니다. SARS-CoV-2 를 선택한 이유는 DMS 데이터, 수렴 진화 위치, 구조 정보 등 3 층 GT 를 모두 갖춘 유일한 병원체이기 때문입니다.

#### 3.2.3.1 정답 기준이 방법 간 차이를 구분할 수 있는가

Stage 1 에서는 세 가지 출처의 정답을 사용하여 평가 도구의 구분 능력을 검증합니다: 1. **DMS 기능 부위:** Dadonaite et al. (2024) 의 Spike 단백질 DMS 실험에서 상위 20% 기능 영향 위치 2. **합성 데이터:** 알려진 위치에 신호를 삽입한 통제 실험 3. **7 개 기능 영역:** RBD, NTD, furin cleavage site 등 총 1,251 뉴클레오타이드

#### 3.2.3.2 기존 도구 (MutClust) 를 개선하여 탐지 기준선 확립

유일한 바이러스 전용 핫스팟 탐지 도구인 MutClust 의 원래 버전 (v1) 을 단계적으로 개선하여, 도메인 지식과 자동 클러스터링을 결합한 Hybrid 버전이 최고 성능 (hotspot-score **0.778**) 을 달성했습니다. 참고로 무작위 기준선 (uniform random position selection, n\_det=200) 은 hotspot-score  $\approx$  **0.018** 로, MutClust-Hybrid 는 무작위 대비 **약 43 배** 성능을 보입니다. 이 결




Figure 2: 11 개 병원체의 3 층 정답 분포. 각 수평 막대는 표면 단백질 서열이며, 파란색 (Layer A: 수렴 진화) 과 초록색 (Layer B: 정화 선택) 위치가 아미노산 좌표에 매핑됨. 단백질 길이는 261 AA(EV-A71 VP1) 부터 1,330 AA(MERS Spike) 까지 다양하며, 주석 위치의 밀도와 분포가 병원체마다 크게 다를 수 있다.

과가 Stage 1 의 탐지 기준선이 됩니다. Stage 2 에서는 v1 을 14 개 탐지 패밀리 중 하나로 유지합니다 (v2c 는 H-score 전용이라 다른 점수 유형에 적용 불가).

### 3.2.3.3 평가 지표가 정확도와 재현성을 동시에 반영하는가 (Hotspot-score)

Stage 1 전용 평가 지표:

$$\text{hotspot-score} = \frac{\text{recall} + \text{precision} + \text{stability}}{3}$$

각 성분의 의미:

- **Recall (재현율)**: Layer A 위치 중 탐지 방법이 실제로 찾아낸 비율. 예: SARS-CoV-2 에 Layer A 위치가 25 개 있는데 그중 15 개를 찾았다면  $\text{recall} = 15/25 = 0.60$ . 높을수록 놓치는 핫스팟이 적음.
- **Precision (정밀도)**: 핫스팟이라고 보고한 위치 중 실제 Layer A 에 속하는 비율. 예: 100 개를 핫스팟으로 보고했는데 15 개만 Layer A 에 포함되면  $\text{precision} = 15/100 = 0.15$ . 높을수록 위양성이 적음.
- **Stability (안정성)**: 80% 부분추출 100 회 반복의 평균 Jaccard 유사도. 입력 서열의 20% 를 무작위로 제거한 후 재탐지했을 때 원래 결과와의 일치도 (Jaccard 유사도) 를 측정합니다.

**핵심 고려사항 6:** 왜 F1 이 아닌  $(\text{recall} + \text{precision} + \text{stability})/3$  인가?

$F1 = 2 \times (\text{recall} \times \text{precision}) / (\text{recall} + \text{precision})$  은 recall 과 precision 을 하나의 숫자로 합쳐버리므로, stability 와의 상호작용이 보이지 않습니다. 예를 들어 HDBSCAN-Auto 는  $F1=0.146$ (낮음) 이지만  $\text{recall}=0.944$ (매우 높음),  $\text{stability}=0.788$ (높음) 입니다.  $F1+\text{stability}$  구조에서는 이 방법이 과소평가되지만,  $(\text{recall}+\text{precision}+\text{stability})/3$  구조에서는 높은 재현율과 안정성이 적절히 반영됩니다.

### 3.2.3.4 H-score 의 한계와 대안 (Stage 1 전용)

H-score 는 시간이 지나면 대부분의 위치에서 높은 값을 갖게 되어 핫스팟과 비핫스팟의 구분이 어려워지는 **포화 (saturation)** 현상이 있습니다. 이를 보완하기 위해 Stage 1 에서 엔트로피 단독, 시간적 빈도 변화율 등 8 가지 대안 점수화 방법을 개발하여 비교했습니다. 이 대안들은 Stage 1 분석에서만 사용되며, Stage 2 에서는 아래 20 가지 점수화 유형으로 대체됩니다.

**3.2.4 Stage 2: 11-Pathogen 교차비교 벤치마크** Stage 1 에서 프레임워크가 작동함을 확인했으므로, 이제 핵심 질문에 답합니다: “어떤 생물학적 정보가 어떤 바이러스에서 가장 효과적인가?”

이를 위해 20 가지 점수화 유형  $\times$  14 개 탐지 패밀리 (39 변형)  $\times$  11 개 병원체 = **8,580 회** 조합을 평가합니다. 각 조합의 MCC 를 계산하고, 3-way ANOVA 로 성능 차이의 원인을 분리합니다.

#### 3.2.4.1 20 가지 점수화 유형 — 어떤 생물학적 정보를 사용하는가

같은 MSA 데이터라도 어떤 관점에서 점수를 매기느냐에 따라 다른 위치가 높은 점수를 받습니다. 예를 들어 빈도 기반 점수는 “변이가 얼마나 자주 일어나는가” 를 보지만, 계통 분석 점수는 “그 변이가 독립적으로 여러 번 출현했는가 (양성 선택)” 를 봅니다. 6 개 카테고리:

- **빈도 기반 (3 가지)**: MSA 에서 직접 관찰되는 변이 빈도. 가장 직관적이지만 founder effect 에 취약
- **MSA 파생 (3 가지)**: 빈도를 넘어 다양성 (엔트로피) 과 수렴 진화 횟수 (homoplasy) 를 측정
- **계통발생 (4 가지)**: 코돈 수준에서 자연선택 방향 (양성/정화) 을 직접 추정. FUBAR 는 베이지안 방법으로 위치별 선택 압력을 계산
- **구조 기반 (3 가지)**: 단백질 3D 구조에서 유연성 (pLDDT), 표면 노출도 (SASA), 아미노산 화학적 차이 (Grantham) 를 측정
- **AI 기반 (5 가지)**: 대규모 단백질 서열로 학습된 언어 모델 (ESM-2, Tranception) 이 “이 위치의 변이가 얼마나 예상 밖인가” 를 평가
- **복합 (2 가지)**: 여러 정보를 가중 결합한 점수

| 카테고리       | 유형                                         | 정보 원천                               | 설명                                                      |
|------------|--------------------------------------------|-------------------------------------|---------------------------------------------------------|
| 빈도 기반 (3)  | freq<br>rare_freq<br>freq_with_indel       | MSA 변이 빈도<br>MSA 희귀 변이<br>MSA+indel | 위치별 변이 빈도<br>5% 미만 변이 비율<br>삽입/결실 포함 빈도                 |
| MSA 파생 (3) | entropy<br>entropy_with_indel<br>homoplasy | Shannon 엔트로피<br>갭 포함 엔트로피<br>계통수    | 아미노산 다양성<br>갭 문자 포함<br>독립적 수렴 변이<br>횟수                  |
| 계통발생 (4)   | dN/dS proxy                                | 코돈 정렬                               | Nei-Gojobori 비율                                         |
|            | FUBAR prob                                 | HyPhy FUBAR                         | 양성 선택 사후 확률                                             |
|            | FUBAR pos_sel<br>FUBAR Bayes factor        | HyPhy FUBAR<br>HyPhy FUBAR          | 양성 선택 속도<br>양성 선택 베이지 팩터                                |
| 구조 기반 (3)  | pLDDT inverse                              | AlphaFold2                          | 낮은 신뢰도 = 유연 영역                                          |
|            | SASA<br>Grantham distance                  | 3D 구조<br>물리화학                       | 표면 노출도<br>치환의 화학적 차이                                    |
| AI 기반 (5)  | ESM-2 LLR                                  | PLM                                 | 변이 예측<br>log-likelihood ratio                           |
|            | Tranception †                              | PLM                                 | 자기회귀 변이 효과 (프록시)                                        |
|            | semantic change<br>stability †             | ESM-2 임베딩<br>치환 행렬 프록시              | 임베딩 공간 코사인 거리<br>BLOSUM62 기반 안정성 프록시 (radical 치환 → 불안정) |
|            | stability_structural                       | 구조 가중 프록시                           | BLOSUM62 점수 × ESMFold pLDDT (잘 접힌 영역일수록 영향 큼)           |
| 복합 (2)     | EVEscape composite †                       | EVEscape 스타일 프록시                    | ESM-2 LLR × SASA × Grantham 곱 (적합도 × 접근성 × 비유사도 프록시)    |
|            | EqualWeight                                | 전체 평균                               | 모든 유형의 동등 가중 평균                                         |

† 구현 주의사항: - **Tranception**: 실제 Tranception 자기회귀 모델이 아닌 **ESM-2 masked-marginal pseudo-perplexity** 프록시 사용. 두 방법 모두 “단백질 언어 모델 하에서 위치별 비개연성”을 측정하지만 절대값은 다름. - **stability / stability\_structural**: 전체 물리 기반  $\Delta\Delta G$  예측기 (FoldX, RoseTTAFold) 는 11 개 병원체 × 39 개 detector 규모에서 계산 비용이 비현실적이라, **BLOSUM62 치환 행렬 기반 프록시** 사용. radical 치환 (낮은 BLOSUM62) 일수록 destabilizing 점수 부여. structural 변형은 ESMFold pLDDT 를 가중치로 추가. - **EVEscape composite**: 실제 EVE 모델 훈련은 11 개 병원체 전체에 비현실적이라, ESM-2 LLR 을 EVE fitness 자리에 대체하여 **ESM-2 LLR × SASA × Grantham** 의 곱셈 결합 사용. EVEscape 원

논문 (Thadani 2023) 의 “fitness  $\times$  accessibility  $\times$  dissimilarity” 정신을 따르되 fitness 는 PLM 점수로 대체.

: Stage 2 점수화 유형 20 가지 (6 개 카테고리)

### 3.2.4.2 14 개 탐지 알고리즘 — 점수에서 핫스팟 영역을 어떻게 찾는가

핫스팟 탐지 = “계놈 위의 숫자 배열에서 비정상적으로 높은 영역을 찾아라” 라는 신호 탐지 문제입니다. 이 문제는 의학, 공학, 금융에서 이미 풀어온 문제이며, 아래 14 개 알고리즘은 각각 다른 수학적 원리로 접근합니다. 각 알고리즘은 **다수의 파라미터 설정** (총 39 변형) 으로 테스트하여, “알고리즘 A 가 B 보다 좋다” 는 결론이 특정 파라미터에 의존하지 않도록 했습니다.

Table 11: 14 개 탐지 알고리즘 패밀리

| 패밀리           | 원리                         | 변형 수 | 특기 사항                                   |
|---------------|----------------------------|------|-----------------------------------------|
| FreqThresh    | 상위 k% 점수 절단                | 4    | 기준선 (최소한 이것보다 나아야 함)                    |
| AdaptiveKnee  | 자동 꺾임점 탐지                  | 1    | 파라미터 불필요                                |
| AdaptWin      | 적응적 윈도우 확장                 | 2    | seed 기반 양방향 확장                          |
| Wavelet       | 다중 스케일 이상 신호               | 3    | <b>평균 성능 1 위</b>                        |
| Spectral      | FFT 고주파 필터링                | 2    | 주기적 패턴 탐지                               |
| CUSUM         | 누적합 변화점                    | 3    | RSV 에서 강점                               |
| KDE           | 커널 밀도 추정                   | 3    | 평균 MCC 음수이지만 H3N2/MERS/Norovirus 에서 1 위 |
| ScoreDBSCAN   | 밀도 클러스터링                   | 2    | SARS-CoV-2 에서 강점                        |
| SlidingTest   | 슬라이딩 윈도우 z-검정              | 2    | HIV-1 에서 강점                             |
| LocalContrast | 국소-전체 대비                   | 3    | SlidingTest 와 독립적 (r=0.02)              |
| GradPeak      | 기울기 피크 탐지                  | 2    | —                                       |
| Bayes         | 베이저안 사후 확률                 | 2    | —                                       |
| SWAN          | 슬라이딩 윈도우 적응 정규화            | 9    | 윈도우 $\times$ 정규화 조합                     |
| MutClust-Orig | CCM seed + adaptive DBSCAN | 1    | 유일한 바이러스 전용 도구, 레거시 기준                  |

14 개 패밀리의 파라미터 변형은 39 가지: Wavelet( $t \in \{1.0, 1.5, 2.0\}$  표준편차), KDE( $0.5 \times 1 \times 2 \times$  Silverman), SlidingTest(window 20/50), GradPeak(smooth 5/11), LocalContrast(window 10/20/50), CUSUM( $\delta \in \{0.5, 1.0, 2.0\}$ ), ScoreDBSCAN( $\epsilon=10/15$ , min\_samples=3), Spectral(고 주 파 cutoff 5%/10%), Bayes( $\pi=0.05/0.10$ , Gaussian 가능도), AdaptWin(50/75 백분위), FreqThresh( $k=1/3/5/10$ ), SWAN(window  $\times$  normalization 9 가지), AdaptiveKnee/MutClust-Orig 파라미터 없음.

### 3.2.4.3 11 개 병원체 간 통제되지 않는 차이와 대응

이상적인 실험이라면 모든 병원체의 서열 수, 단백질 길이, 시간 범위를 동일하게 맞춰야 합니다. 그러나 실제 바이러스 데이터는 이것이 불가능합니다:

- 고유 서열 수: MERS 530 개 vs Influenza B 5,019 개 (9.5 배 차이)
- 단백질 길이: EV-A71 261 AA vs MERS 1,330 AA (5.1 배 차이)
- 시간 범위: SARS-CoV-2 약 5 년 (2019-2024) vs H3N2/Rabies 약 50 년
- Layer A 양성률: MERS 0.7% vs HCV 15.9%

이 차이가 결과에 미치는 영향을 세 가지 방법으로 완화합니다: (1) 부분추출 분석에서 MCC 가 약 1,000 개 서열부터 안정화됨을 확인, 이에 따라 서열 수 차이가 주된 원인이 아님, (2) ANOVA 의 scoring  $\times$  pathogen 상호작용 ( $\omega^2=0.296$ ) 은 각 병원체 **내부**에서의 비교이므로 서열 수가 동일하게 고정됨, (3) 서열 수를 최소 (530 개) 로 균일화하면 통계 검정력이 크게 감소하므로 현실적이지 않음.

**3.2.5 Evaluation and Statistical Design (평가 및 통계 설계)** 아래는 Stage 1 과 Stage 2 에서 사용하는 평가 지표와 통계 분석 방법입니다.



### 3.2.5.1 무엇으로 성능을 측정하는가 (MCC, Constrained FPR, DMS F1)

탐지 방법이 찾아낸 핫스팟이 정답과 얼마나 일치하는지를 여러 관점에서 평가합니다.

- **Hotspot-score** (Stage 1 전용): 정확도 (recall, precision) 와 재현성 (stability) 을 균형 있게 측정합니다. 예를 들어 MutClust-Hybrid 의 hotspot-score 0.778 은 “25 개 정답 중 약 66% 를 찾고 (recall), 찾은 것의 97% 가 진짜이며 (precision), 데이터를 변동시켜도 71% 일관된 결과를 냄 (stability)” 을 종합한 값입니다.
- **MCC** (Stage 2, Layer A 기반): Layer A(수렴 진화 위치) 를 정답 (양성), 나머지 전체를 오답 (음성) 으로 두고, “탐지 방법이 정답과 오답을 얼마나 잘 구분하는가” 를 -1(완전 반대)~+1(완벽 일치) 로 측정합니다. 0 이면 랜덤 수준입니다. 핫스팟은 전체 게놈의 1~16% 에 불과하므로 극심한 불균형 상황인데, MCC 는 이런 불균형에서도 TP/TN/FP/FN 4 가지를 모두 고려하여 F1 보다 공정하게 평가합니다.
- **Constrained FPR**: “구조적으로 필수적인 위치 (Layer B) 를 핫스팟이라고 잘못 판정하는 비율” 입니다. 이 값이 높으면 백신/약물 타겟 설정에서 위험한 오류가 발생합니다. 예를 들어 HR1/HR2(세포막 융합 필수 구조) 를 핫스팟이라 판정하면 불필요한 실험 자원을 낭비하게 됩니다.
- **DMS F1**: “실험실에서 기능적으로 중요하다고 확인된 위치 (Layer C) 와 탐지 결과의 일치도” 입니다. Layer A(진화 패턴) 와 독립적인 실험 데이터로 교차 검증하여, 벤치마크 결과가 순환 논리가 아님을 확인합니다.

Stage 1 에서 Stage 2 로 지표를 전환한 이유: hotspot-score 의 stability 성분은 데이터를 20% 무작위 제거하고 재탐지하는 방식인데, 정렬 길이 (261~1,330 AA) 와 MSA 크기 (530~5,019 서열) 가 병원체마다 크게 달라 부분추출 결과를 병원체 간에 직접 비교할 수 없습니다.

### 3.2.5.2 성능 차이의 원인을 어떻게 분리하는가 (ANOVA, Friedman, LOPO)

8,580 회 평가 결과에서 “성능 차이가 어떤 요인 때문인지” 를 4 가지 독립적 방법으로 검증합니다. 4 가지를 모두 사용하는 이유는 하나의 통계 검정만으로는 “우연일 수 있다” 는 반론이 가능하기 때문입니다.

- **3-way ANOVA**: 성능 분산을 “점수화 유형 (20) × 탐지 알고리즘 (14) × 병원체 (11)” 세 요인으로 분해합니다. 각 요인이 전체 성능 차이의 몇% 를 설명하는지 ( $\omega^2$ , 0~1 범위) 를 계산합니다. 예: scoring × pathogen 의  $\omega^2=0.296$  은 “이 상호작용이 성능 분산의 29.6% 를 설명한다” 는 뜻입니다.
- **Friedman 검정**: 11 개 병원체 각각에서 상위 20 개 조합의 순위를 매기고, 모든 병원체에서 일관되게 높은 순위를 유지하는 조합이 있는지 검정합니다.  $p=0.990$ (비유의) 은 “그런 조합이 없다 — 순위가 병원체마다 뒤바뀐다” 를 의미합니다.
- **LOPO (Leave-One-Pathogen-Out)**: 10 개 병원체에서 가장 좋았던 조합을 남은 1 개에 적용합니다. 0/11 일치 자체는 무작위 조합 permutation 에서도  $P \approx 0.96$  으로 흔하게 발생 (null-consistent) 하므로, 단독 증거가 아닌 oracle vs generalized MCC 갭 (0.265) 과 ANOVA 상호작용의 corroboration 으로 해석합니다.
- **BCa bootstrap CI**: MCC 값의 95% 신뢰 구간을 추정하여 결과가 통계적으로 안정적인지 확인합니다.

### 3.2.5.3 서로 다른 점수 유형을 공정하게 비교할 수 있는가

점수화 유형 간 비교에서 고려해야 할 사항:

- **스케일 차이**: 점수화 유형마다 값의 범위가 다름 (freq: 0~1, homoplasy: 0~53, plddt: 0~100). 그러나 탐지 방법 대부분이 내부적으로 스케일을 보정 (percentile, t-test, z-정규화 등), 이에 따라 외부 정규화 없이도 공정하게 작동.
- **입력 데이터 품질 차이**: 빈도는 MSA 만 필요하나, FUBAR 는 트리 품질, PLM 은 학습 데이터 편향, 구조는 예측 정확도에 의존. 이 차이는 완전히 통제할 수 없으며 Discussion 에서 한계로 논의.
- **카테고리별 scoring 수 불균형**: AI 기반 5 개 vs homoplasy 1 개, 이에 따라 6-카테고리 수준 ANOVA( $\omega^2=0.103$ ) 로 카테고리 수 보정 후에도 결론 일관.

- **Layer A 와 빈도 상관 (pathogen-specific):** per-pathogen point-biserial rho(Layer A 소속, 위치별 빈도) 평균 0.12 (HCV 0.33, Influenza B 0.26, Norovirus 0.23 에서 중간 정도; SARS-CoV-2/MERS/EV-A71 은 거의 0). 빈도 vs 엔트로피 벡터 자체의 상관은  $\rho=0.97$  로 매우 높아 feature-level collinearity 존재. 이에 따라 Layer C(DMS) 로 독립 검증 수행.

## Chapter 4. Experimental Results (실험 결과)

Ch3 에서 설계한 프레임워크 (3.2.1 참조) 를 실제로 적용한 결과입니다. Stage 1 에서 SARS-CoV-2 로 도구를 검증한 후, Stage 2 에서 11 개 병원체로 확장합니다.

### 4.1 Single-Pathogen Benchmark: SARS-CoV-2 (Stage 1)

Stage 1 은 다음 5 개 실험을 순서대로 수행하며, 각 실험이 다음 실험을 정당화하는 누적 구조입니다.

| 실험              | 핵심 질문                       |
|-----------------|-----------------------------|
| 4.1.1 합성 데이터    | 평가 도구가 좋은 방법과 나쁜 방법을 구분하는가? |
| 4.1.2 게놈 핫스팟 지도 | 탐지 결과가 실제 게놈에서 생물학적으로 타당한가? |
| 4.1.3 다중 GT 검증  | 정답 기준을 바꾸면 최적 방법도 달라지는가?    |
| 4.1.4 DMS 검증    | 실험실 데이터와도 일치하는가?            |
| 4.1.5 GISAID 검증 | 실제 데이터에서도 유효한가?             |
| 4.1.6 안정성 검증    | 결과가 데이터 양에 따라 흔들리지 않는가?     |

**4.1.1 합성 데이터 테스트 — “평가 도구가 방법 차이를 구분하는가?”** 첫 번째로 해야 할 일은 평가 도구가 “좋은 방법과 나쁜 방법을 구분할 수 있는지” 확인하는 것입니다. 이를 위해 **정답을 미리 알고 있는** 통제된 환경을 만듭니다.

29,903 개 위치의 가상 게놈에 7 개 기능 영역 (RBD, NTD 등 총 1,251 개 위치) 에 높은 점수를 인위적으로 심어놓고, 5 가지 MutClust 개선 버전 + 2 가지 기준선 방법이 이 정답을 얼마나 잘 찾는지 비교했습니다.

Table 13: 합성 데이터에서 5 가지 탐지 방법의 성능 비교 (평가 도구 구분 능력 검증)

| 방법                     | Precision    | Recall       | F1           | Stability    | Hotspot-score |
|------------------------|--------------|--------------|--------------|--------------|---------------|
| MutClust-Original      | 0.991        | 0.504        | 0.668        | 0.418        | 0.638         |
| MutClust-Fixed         | 0.988        | 0.506        | 0.669        | 0.445        | 0.646         |
| MutClust-dNdS          | 0.988        | 0.506        | 0.669        | 0.445        | 0.646         |
| <b>MutClust-Hybrid</b> | <b>0.968</b> | <b>0.659</b> | <b>0.785</b> | <b>0.706</b> | <b>0.778</b>  |
| HDBSCAN-Auto           | 0.079        | 0.944        | 0.146        | 0.788        | 0.604         |

**핵심 발견:** 5 가지 방법 중 MutClust-Hybrid 가 F1=0.785 로 최고 균형을 달성했습니다. 반면, HDBSCAN-Auto 는 재현율이 0.944 로 거의 모든 정답을 찾았으나 정밀도가 0.079 에 불과하여 위양성이 과다했습니다. 이 결과는 도메인 지식 (어떤 위치를 시드로 삼을지) 과 데이터 기반 경계 결정 (HDBSCAN) 을 결합할 때 가장 좋은 성능이 나온다는 것을 보여줍니다.

**중요한 주의:** 이 합성 결과 (F1 0.785) 는 **실제 성능을 과대추정**합니다. 뒤의 실제 GISAID 데이터에서는 F1 이 0.123 으로 급락합니다. 합성 실험의 목적은 절대 성능 측정이 아니라, 평가 도구가 방법 간 차이를 구분할 수 있는지 확인하는 것입니다.

**4.1.2 게놈 핫스팟 지도 — “탐지 결과가 생물학적으로 타당한가?”** 합성 데이터에서 방법 차이가 구분됨을 확인했으므로, 이제 **실제 게놈 위에서** 탐지 결과가 생물학적으로 타당한지 시각적으로 확인합니다.

**핵심 발견:**

- 탐지 결과 (빨간색) 와 알려진 기능 영역 (초록색) 이 **대체로 겹침**, 이에 따라 방법이 생물학적으로 의미 있는 영역을 찾고 있음
- Spike 단백질 바깥 (ORF1ab, N, M 등) 에는 핫스팟이 거의 없음, 이에 따라 **표면 단백질에 양성 선택**이 집중된다는 생물학적 예상과 일치




Figure 3: 게놈 핫스팟 지도. SARS-CoV-2 전체 게놈 (29,903 위치) 에서의 3 층 비교. 위: H-score 분포. 가운데: 탐지 결과 (빨간색). 아래: 알려진 기능 영역 (초록색). Spike 유전자 (21,563~25,384) 영역에 H-score와 탐지 결과가 집중되어 있으며, 나머지 게놈에는 신호가 거의 없다.

- 다만 RBD(수용체 결합 도메인) 내부에서도 탐지/미탐지 위치가 혼재, 이에 따라 **정확한 위치 수준에서는 완벽하지 않음** (이것이 Stage 2 에서 다양한 정보 유형을 비교하는 동기)

지금까지 하나의 정답 기준 (기능 영역) 만 사용했으므로, 다음으로 정답 기준을 바꾸었을 때 결과가 달라지는지 검증합니다.

#### 4.1.3 다중 Ground Truth 검증 — “정답 기준이 달라지면 최적 방법도 달라지는가?” “핫스팟이 중요한 이유” 는 여러 가지입니다 — 면역 회피 (수렴 진화), 실험적 기능 (DMS), 구조적 위치 (기능 영역). 정답 기준을 바꾸면 최적 방법도 달라지는가?

Table 13 은 같은 SARS-CoV-2 데이터에 대해 4 가지 서로 다른 정답 기준 (기능 영역, DMS, 수렴 진화, 수렴 진화-strict) 으로 평가했을 때 각각 다른 방법이 최적으로 나타남을 보여줍니다. 이 결과는 **단일 정답 기준에 의존하면 특정 방법이 과대평가될 위험**이 있음을 의미합니다.

Table 14: 다중 정답 기준별 최적 방법 비교

| 정답 기준            | 최적 방법             | F1    | Enrichment | 위치 수 |
|------------------|-------------------|-------|------------|------|
| 기능 영역 (439)      | TC-freq-v2        | 0.474 | —          | 439  |
| DMS-escape (252) | Saturated H-score | 0.315 | —          | 252  |
| 수렴 진화 (97)       | CH-score          | 0.188 | 1.70×      | 97   |
| 수렴 진화-strict     | TC-freq-v3        | 0.108 | 3.43×      | —    |

이 결과는 **정답 기준마다 최적 방법이 다르다**는 것을 보여주며, 만능 방법이 없다는 첫 번째 증거입니다.

Figure 4~5 는 4 가지 정답 기준 (기능 영역, DMS, 수렴 진화, 수렴 진화-strict) 으로 동일한 방법들을 평가한 결과입니다. (A) 각 기준별 최고 F1 을 달성한 방법이 서로 다르며, (B) enrichment 히트맵에서도 방법-GT 조합에 따른 성능 차이가 뚜렷합니다.

다중 GT 평가. (A) 4 가지 정답 기준별 최고 F1. 정답 기준에 따라 최적 방법이 달라진다: 기능 영역 → TC-freq-v2, DMS → Saturated H-score, 수렴 진화 → CH-score. 아직 SARS-CoV-2 하나만의 결과인데도, 이미 “만능 방법은 없다” 의 첫 번째 힌트가 나타난다. (B) 점수화 방법 × GT 별 enrichment 히트맵.

다중 GT 평가 (계속). (C) GT 간 Jaccard 중첩 행렬 — 비대각선 값이 0.006 으로, 세 GT 가 거의 겹치지 않는다. 이는 3 층 GT 가 각각 독립적인 정보를 제공한다는 것을 정량적으로 보여준다. (D) 수렴 vs 비수렴 위치의 점수 분포.

**4.1.4 DMS 실험 데이터 검증 — “실험실 데이터와도 일치하는가?”** 지금까지의 정답 기준 (기능 영역, 수렴 진화) 은 문헌에서 가져온 것이므로, 여기서는 **실험실에서 직접 측정한 DMS 데이터**로 독립 검증합니다.

Figure 6~7 은 DMS 실험실 데이터로 독립 검증한 결과입니다.

(A) 에서 Saturated H-score 는 DMS 기준  $F1=0.315$  로 최고이지만, 기능 영역 기준에서는 TC-freq-v2( $F1=0.474$ ) 에 밀립니다. 이는 **같은 방법이라도 정답 기준에 따라 성능 순위가 역전됨**을 보여줍니다. 이 역전이 중요한 이유는 단일 정답 기준만 사용하면 특정 방법이 과대평가되는 편향이 발생하기 때문이며, 이것이 3 층 GT 를 설계한 핵심 동기입니다.

(B) 의 Cohen’s d 는 “각 점수화 방법이 핫스팟 위치와 비핫스팟 위치의 점수를 얼마나 잘 분리하는가” 를 정량화합니다. CH-score 가 기능 영역 기준으로 가장 높은 효과 크기 ( $d \approx 0.25$ ) 를 보이지만, 전반적으로 효과 크기가 0.3 미만으로 작습니다. 이는 **어떤 단일 점수도 핫스팟/비핫스팟을 명확히 분리하지 못한다**는 것을 의미하며, Stage 2 에서 20 가지 점수와 유형을 체계적으로 비교해야 하는 근거가 됩니다.

DMS 검증. (A) DMS 기반 GT vs 기능 영역 GT 에서의 F1 비교 — 같은 방법이 어떤 GT 를 기준으로 보느냐에 따라 성능이 크게 달라진다. (B) Cohen’s d 효과 크기 (두 그룹 평균 차이를 표준편차로 나눈 값 — 0.8 이상이면 큰 차이).

DMS 검증 (계속). (C) 점수와 DMS 적합도의 상관 산점도. (D) DMS-escape 위치에 대한 Precision-Recall 곡선.

**핵심 발견:**

- 같은 방법이라도 **어떤 정답 기준으로 평가하느냐**에 따라 성능이 크게 달라짐
- DMS 기반 GT(실험 데이터) 와 기능 영역 GT(문헌 기반) 에서 최적 방법이 **서로 다름**, 이에 따라 Layer A 와 Layer C 는 독립적인 평가 차원
- 이것은 3 층 GT 설계의 정당성을 뒷받침: 단일 정답 기준에 의존하면 특정 방법이 과대/과소 평가될 위험

**4.1.5 실제 GISAID 데이터 벤치마크** 합성 데이터가 아닌 실제 GISAID 2020-2021 서열에서 계산한 H-score(각 위치의 변이 활발도 점수, hotspot-score 와 다름) 를 탐지 알고리즘에 입력하여 검증합니다. 실제 데이터에서는 29,903 개 게놈 위치 중 342 개 (1.14%) 만 H-score > 0 인 **극도로 희소한 분포**를 보여, 합성 대비 F1 이 0.785 에서 0.123 으로 급락했습니다.

그러나 **enrichment(정답 집중 비율)** 는 6.9~8.0 배로 유지되었습니다. Enrichment 란 “탐지 영역에 정답이 랜덤 기대치 대비 몇 배 집중되어 있는가” 를 나타냅니다. 예를 들어 enrichment 7.28× 는, 탐지 방법이 보고한 영역 내 정답 (Layer A) 비율이 전체 게놈의 정답 비율보다 7.28 배 높다는 의미입니다. 즉, F1 이 낮더라도 “찾은 것들은 생물학적으로 의미 있는 위치” 임을 확인합니다.

Table 14 는 이 결과를 보여줍니다.

Table 15: 실제 GISAID 데이터 벤치마크 결과

| 방법              | Precision    | Recall       | F1           | Enrichment |
|-----------------|--------------|--------------|--------------|------------|
| MutClust-Hybrid | 0.305        | 0.077        | 0.123        | 7.28×      |
| MutClust-Fixed  | 0.295        | 0.079        | 0.125        | 7.04×      |
| Sliding window  | <b>0.323</b> | <b>0.600</b> | <b>0.420</b> | 7.73×      |
| HDBSCAN-Auto    | —            | —            | —            | — (실패)     |

**핵심:** 합성 데이터 대비 실제 데이터에서 F1 이 0.785 에서 0.123 으로 크게 하락했습니다. 그러나 enrichment ratio 는 6.9~8.0 배를 유지하여 **생물학적 타당성은 보존**되었습니다. 또한 합성 데이터에서 1 위였던 MutClust-Hybrid 대신 Sliding window 이 1 위로 올라서, **데이터 특성에 따라 최적 방법이 달라진다**는 것이 실제 데이터에서도 확인되었습니다.

마지막으로, 지금까지의 결과가 데이터 양에 따라 달라지지 않는지 안정성을 검증합니다.

**4.1.6 안정성 검증 — 결과가 입력 데이터 크기와 파라미터에 안정적인가?** Stage 2 로 확장하기 전에, Stage 1 결과가 데이터 크기나 파라미터 설정에 의존하지 않는지 두 가지 검증을 수행합니다.

아래 그림의 좌측은 입력 서열 수를 50~5,000 개로 변화시킨 결과입니다. 약 1,000 개 서열부터 hotspot-score 가 약 0.62 로 안정화되며, 본 벤치마크의 서열 수 (662~5,325) 는 모두 이 수렴점 이상이므로 결과가 데이터 부족의 산물이 아님을 확인합니다. 우측은 hotspot-score 의 가중치 (recall, precision, stability) 를 171 가지 조합으로 변경한 결과입니다. MutClust-Hybrid 가 **71.9% 의 조합에서 1 위를 유지**하여, 순위가 특정 가중치 설정에 의존하지 않음을 확인합니다.




Figure 4: 표본 크기 수렴 — 약 1,000 개 서열부터 hotspot-score 약 0.62 로 안정화. 본 벤치마크 서열 수 (662~5,325) 는 수렴점 이상.

**Stage 1 요약:** 평가 도구 (hotspot-score, 3 층 GT) 가 작동함을 확인했습니다. 방법 간 차이를 구분할 수 있고, 결과가 안정적이며, 생물학적으로 의미 있는 영역을 탐지합니다. 그리고 첫 번째 힌트를 발견했습니다 — **같은 바이러스 내에서도 정답 기준에 따라 최적 방법이 달라집니다.** 이것이 Stage 2 로 나아가는 동기입니다.

## 4.2 Robustness and Sensitivity Validation (안정성·민감도 검증)

Stage 1 결과가 데이터 부족이나 특정 파라미터 설정의 산물이 아닌지 확인하기 위해 세 가지 추가 검증을 실시했습니다:

- **표본 크기 수렴 검증:** 입력 서열 수를 50~5,000 으로 변화시킨 결과 약 1,000 개 서열부터 hotspot-score 가 0.62 수준으로 안정화됩니다. 본 벤치마크가 쓴 서열 수 (662~5,325) 는 모두 수렴점 이상이므로 결과는 데이터 부족의 산물이 아닙니다.
- **가중치 민감도 검증:** hotspot-score 의 세 component(recall, precision, stability) 에 대한 171 가지 가중치 조합을 시험한 결과 MutClust-Hybrid 가 71.9% 에서 1 위를 유지. 순위가 특정 가중치 설정에 의존하지 않습니다.
- **Bootstrap CI:** region-level BCa bootstrap 95% CI [0.323, 0.635] 로 MutClust-Hybrid 의 성능 구간이 다른 방법과 유의미하게 분리됩니다.

이 세 가지 검증이 통과하면 Stage 2 로 확장 가능하다고 판단했습니다.




Figure 5: 파라미터 민감도 —  $\gamma \times d$  파라미터 조합별 F1. 171 가지 가중치 조합 중 71.9% 에서 MutClust-Hybrid 1 위 유지.

### 4.3 Cross-Pathogen and Structural Validation

SARS-CoV-2 에서 확인된 프레임워크를 다른 바이러스에 확장 적용하여, Stage 2 대규모 벤치마크의 필요성을 확인합니다. 먼저 H3N2 에 적용한 결과, MutClust-Fixed 가 MutClust-Hybrid 를 앞서 (HS 0.661 vs 0.577) Stage 1 과 순위가 역전되었습니다. 이는 H3N2 에서 모든 위치의 H-score 가 비영점이라 HDBSCAN 의 이점이 사라지기 때문입니다.

아래 표는 각 병원체에서 평균 MCC 가 가장 높은 상위 3 개 scoring 유형을 보여줍니다. **11 개 병원체 모두에서 상위 3 위 안에 드는 단일 scoring 은 존재하지 않으며**, 1 위 scoring 이 6 개 카테고리 전체에 걸쳐 분포합니다. 이것이 Stage 2(8,580 회 체계적 평가) 로 나아가는 직접적 동기입니다.

Table 16: 교차 병원체 MCC 비교 — 각 병원체 상위 3 개 scoring (평균 MCC 기준)

| 병원체         | 1 위 scoring (MCC)         | 2 위                   | 3 위                |
|-------------|---------------------------|-----------------------|--------------------|
| SARS-CoV-2  | fubar_pos_sel (0.078)     | rare_freq (0.050)     | fubar_bf (0.044)   |
| H3N2        | <b>fubar_bf (0.177)</b>   | fubar_pos_sel (0.174) | dnds_proxy (0.135) |
| Norovirus   | <b>homoplasy (0.288)</b>  | freq (0.230)          | entropy (0.227)    |
| HIV-1       | EqualWeight (0.076)       | entropy (0.070)       | semantic (0.066)   |
| Dengue      | homoplasy (0.117)         | entropy_indel (0.065) | EVEscape (0.054)   |
| RSV         | plddt_inv (0.021)         | stability (0.020)     | sasa (-0.001)      |
| Influenza B | <b>freq (0.213)</b>       | dnds_proxy (0.197)    | entropy (0.178)    |
| MERS        | EqualWeight (0.049)       | EVEscape (0.047)      | plddt_inv (0.043)  |
| HCV         | <b>dnds_proxy (0.303)</b> | freq (0.294)          | entropy (0.264)    |
| Rabies      | stab_struct (0.059)       | stability (0.035)     | EVEscape (0.011)   |
| EV-A71      | stab_struct (0.035)       | stability (0.028)     | plddt_inv (0.024)  |

3D 구조 분석: 선형 서열 핫스팟이 공간적으로도 클러스터링됨 (5.92 배 spatial contact enrichment,  $z=13.34$ ).

또한 H-score 는 founder effect 를 양성선택과 혼동하는 문제가 확인되었습니다. 예를 들어 D614G 는 H-score 에서 2 위이지만 homoplasy 에서 1,134 위로, 두 지표 간 상관관계  $\rho=-0.876$ (강한 음의 상관)입니다. 이는 빈도 기반 scoring 의 근본적 한계이며, 다양한 정보 유형이 필요한 이유입니다.

### 4.4 Cross-Pathogen Large-Scale Benchmark (대규모 벤치마크, Stage 2)

**핵심:** 20 scoring x 14 families (39 variants) x 11 pathogens = **8,580 회** 평가

**4.4.1 벤치마크 규모: 8,580 회 평가** 11 개 바이러스 각각에 대해 20 가지 scoring × 39 가지 detection variant = 780 가지 조합의 MCC 를 계산하여 총 8,580 회 평가를 수행했습니다. 이 규모는 바이러스 핫스팟 탐지 분야에서 최대이며, 통계적으로 유의한 ANOVA 와 Friedman 검정을 가능하게 합니다.

**4.4.2 각 바이러스의 최적 방법은 무엇인가** 아래 표는 8,580 회 평가에서 각 병원체의 최고 MCC 를 달성한 점수화-탐지 조합입니다. **11 개 병원체가 모두 서로 다른 최적 조합**을 가지며, 9 개의 서로 다른 점수화 유형이 최적으로 나타나 6 개 카테고리 중 4 개 (빈도 기반, MSA 파생, 계통발생, AI 기반) 에 분포합니다. 이것이 “만능 방법은 없다” 는 핵심 발견의 직접적 증거입니다.

Table 17: 11 개 병원체별 최적 점수화-탐지 조합 (MCC 기준)

| 바이러스 | 최적 점수화             | 카테고리  | 최적 탐지               | MCC          |
|------|--------------------|-------|---------------------|--------------|
| HCV  | freq               | 빈도 기반 | SlidingTest(p=0.01) | <b>0.660</b> |
| H3N2 | FUBAR Bayes factor | 계통발생  | Wavelet(t=1.5)      | <b>0.534</b> |



| 바이러스       | 최적 점수화             | 카테고리   | 최적 탐지             | MCC          |
|------------|--------------------|--------|-------------------|--------------|
| Norovirus  | homoplasy          | MSA 파생 | Bayes(prior=0.15) | <b>0.510</b> |
| Flu-B      | freq               | 빈도 기반  | KDE(p=85)         | <b>0.392</b> |
| HIV-1      | entropy            | MSA 파생 | Wavelet(t=2.0)    | <b>0.275</b> |
| Dengue     | entropy_with_indel | MSA 파생 | KDE(p=85)         | <b>0.274</b> |
| EV-A71     | semantic change    | AI 기반  | MutClust-Orig     | <b>0.260</b> |
| Rabies     | stability          | AI 기반  | SWAN(w=20,k=2.0)  | <b>0.248</b> |
| SARS-CoV-2 | Tranception        | AI 기반  | KDE(p=85)         | <b>0.211</b> |
| RSV        | ESM-2 LLR          | AI 기반  | Wavelet(t=2.0)    | <b>0.196</b> |
| MERS       | freq               | 빈도 기반  | KDE(p=85)         | <b>0.196</b> |

**11/11 고유 최적 조합.** 9 개의 서로 다른 점수화 유형이 최적으로 나타남. 6 개 카테고리 중 4 개 (빈도 기반, MSA 파생, 계통발생, AI 기반) 에 걸쳐 분포.

**각 병원체별 생물학적 근거:** - **H3N2 (FUBAR):** 수십 년 계통수에서 양성선택 신호가 강함. dN/dS 기반 방법에 최적 - **Norovirus (homoplasy):** GII.4 에포크 진화, 이에 따라 수렴 변이의 AUC 가 0.944 로 거의 완벽한 예측 - **SARS-CoV-2 (Tranception):** 2019 년 이후 얇은 계통, 이에 따라 PLM 이 넓은 코로나바이러스 진화 맥락을 보상 - **RSV (ESM-2):** 제한된 계통 다양성, 이에 따라 PLM 이 대안 신호 제공 - **EV-A71 (semantic change):** VP1 항원 표면 기능 변화 포착 - **Rabies (stability):** G 단백질 pH 의존 구조 전환 제약 - **HCV (freq):** 과변이 영역 (HVR1/HVR2) quasispecies(준종 — 바이러스가 숙주 안에서 다양한 변이체 집단으로 존재하는 현상) 포화로 빈도가 직접 신호 - **HIV-1 (entropy):** 높은 quasispecies 다양성, 엔트로피가 변이 분포 포착 - **Dengue (entropy\_with\_indel):** 4 가지 혈청형 간 변이 + indel 이 E 단백질 에피토프에서 중요 - **MERS (freq):** 희소 샘플링 (<500 서열), 복잡한 방법은 통계적 힘 부족 - **Influenza B (freq):** Victoria/Yamagata 이중 계통 구조, 이에 따라 빈도가 이중 분포를 직접 반영

Figure 9 는 20 개 점수화 유형 × 11 개 병원체의 MCC 히트맵입니다. 만능 방법이 있었다면 한 열이 전부 진한 색이어야 합니다.




Figure 6: 히트맵 읽는 법: 행 = 11 개 바이러스, 열 = 20 개 점수화 유형. 진한 색 = 높은 MCC. 만능 방법이 있었다면 한 열이 전부 진한 색이어야 합니다. 실제로는 바이러스마다 가장 진한 위치가 다른 열에 있어, 최적 정보가 병원체마다 다를 수 시각적으로 확인할 수 있습니다.

Figure 10 은 6 개 점수화 카테고리별 평균 MCC 를 보여줍니다. 빈도 기반과 MSA 파생이 평균적으로 높지만 오차 막대가 크므로 카테고리 수준 일반화는 불충분합니다.




Figure 7: Scoring 카테고리별 평균 MCC (11 병원체). 빈도 기반과 MSA 파생이 평균적으로 높으나 오차 막대가 크므로 카테고리 수준 일반화는 불충분.

아래 표는 FUBAR 계통발생 점수 (Bayes factor) 가 각 병원체에서 어떤 성능을 보이는지, 전체 최고 MCC 와 비교합니다. H3N2에서는 FUBAR BF 가 **전체 최고 (MCC 0.534)** 를 달성하여 계통발생 신호가 모든 다른 정보 유형을 압도합니다. 반면 Norovirus 나 Dengue에서는 음수 MCC 로, 같은 방법이 바이러스에 따라 최고와 최저를 오갑니다.

Table 18: FUBAR Bayes factor 성능 — 병원체별 비교 (전체 Best MCC 대비)

| 병원체         | 전체 Best MCC | FUBAR BF MCC | FUBAR 순위 | 비고            |
|-------------|-------------|--------------|----------|---------------|
| H3N2        | 0.534       | 0.534        | 1/20     | 전체 최고 = FUBAR |
| SARS-CoV-2  | 0.211       | 0.044        | 3/20     | 상위권           |
| EV-A71      | 0.260       | 0.002        | 6/20     | 중간            |
| RSV         | 0.196       | -0.010       | 7/20     | 중간            |
| HIV-1       | 0.275       | 0.021        | 12/20    | 하위            |
| Influenza B | 0.392       | 0.010        | 13/20    | 하위            |
| MERS        | 0.196       | -0.008       | 15/20    | 하위            |
| Norovirus   | 0.510       | -0.011       | 17/20    | 최하위           |
| Dengue      | 0.274       | -0.037       | 18/20    | 최하위           |

이 표가 보여주는 핵심: FUBAR 는 H3N2에서는 최고이지만 Norovirus/Dengue에서는 최하위. 같은 정보 유형이라도 바이러스에 따라 성능이 극단적으로 달라지며, 이것이 scoring × pathogen 상호작용 ( $\omega^2=0.296$ )의 구체적 사례입니다.

#### 4.4.3 성능 차이의 원인 분해 (ANOVA, Friedman, LOPO)

##### 4.4.3.1 3-way ANOVA — 성능 차이의 원인은 무엇인가?

**왜 필요한가:** 8,580 회 평가에서 성능이 방법마다 다른데, 이 차이가 “점수화 유형 때문인지”, “탐지 알고리즘 때문인지”, “바이러스 때문인지”, 또는 “이들의 조합 때문인지” 분리해야 합니다. ANOVA 는 이 질문에 정량적으로 답합니다.

**결과:** Table 17 은 각 요인이 전체 성능 분산의 몇% 를 설명하는지 ( $\omega^2$ , omega-squared) 를 보여 줍니다.

Table 19: ANOVA 분산 분해 결과

| 요인                 | 설명                | $\omega^2$   | 해석                                |
|--------------------|-------------------|--------------|-----------------------------------|
| scoring × pathogen | 정보 유형 × 바이러스 상호작용 | <b>0.296</b> | <b>최대 (29.6%)</b> — 핵심 발견         |
| pathogen           | 바이러스 주효과          | 0.117        | 바이러스 자체 난이도 차이                    |
| family × pathogen  | 알고리즘 × 바이러스 상호작용  | 0.082        | 알고리즘도 바이러스에 따라 다름                 |
| scoring            | 정보 유형 주효과         | 0.063        | 평균적으로 좋은 정보 유형 존재                 |
| scoring × family   | 정보 유형 × 알고리즘 상호작용 | 0.039        | —                                 |
| family             | 알고리즘 주효과          | 0.013        | <b>최소 (1.3%)</b> — 알고리즘 자체는 거의 무관 |

**해석:** scoring × pathogen(29.6%) 이 family(1.3%) 의 약 23 배입니다. 이는 “어떤 알고리즘을 쓰느냐” 보다 “어떤 정보를 어떤 바이러스에 쓰느냐” 가 압도적으로 중요하다는 것을 의미합니다. Figure 12 는 이 결과를 시각화합니다.

**신뢰 구간과 민감도 분석:** - **Bootstrap 95% CI:** 1,000 회 클러스터 부트스트랩 (11 개 병원체 재샘플링) 으로  $\omega^2=0.296$  의 95% CI = [0.201, 0.346] — CI 하한조차 Cohen 기준 large effect(>0.14) 를 초과하므로 결과 안정적. 5-frame 보강 (standard cluster, wild-cluster Rademacher~[?], phylogenetic block 8 ICTV families, mixed-effects pseudo- $\omega^2$ , Bayesian factor analysis HDI [0.242, 0.388]) 모두 large-effect 임계값 (0.14) 위 유지. - **HCV 제외 민감도:** HCV 의 Layer A 는 수렴 진화가 아닌 **다양화 선택 (diversifying selection)** 기반 (HVR1/HVR2 초변이 영역) 이라 이질성이 있음. HCV 제외 10 개 병원체 ANOVA 에서  $\omega^2_{\{\text{scoring} \times \text{pathogen}\}} = 0.246$  확인 — 효과는 HCV 의 비정형 정답 기준 때문이 아님을 확인.

#### 4.4.3.2 Friedman 검정 — “만능 방법” 이 통계적으로 존재하는가?

**왜 필요한가:** ANOVA 는 “어떤 요인이 중요한지” 를 알려주지만, “특정 조합이 모든 바이러스에서 일관되게 1 위인지” 는 알려주지 않습니다. Friedman 검정은 비모수 (정규분포 가정 불필요) 방식으로 **순위의 일관성**을 검정합니다.

**방법:** 11 개 바이러스 각각에서 상위 20 개 scoring-detection 조합의 순위를 매기고, 모든 바이러스에서 순위가 일관된 조합이 있는지 검정합니다.

**결과:** -  $\chi^2 = 7.69$ , **p = 0.990** (비유의 — 일관된 순위 없음) - Kendall W = 0.037 (순위 일치도 — 0 이면 완전 불일치, 1 이면 완전 일치. 0.037 은 거의 합의 없음)

**해석:** p=0.990 은 “상위 20 개 조합 중 어떤 하나도 모든 바이러스에서 일관되게 우위를 점하지 못한다” 는 것을 의미합니다. 즉 **만능 방법은 통계적으로 존재하지 않습니다.** (참고: 이전 9-scoring 분석에서는  $\chi^2=42.44$ , p=0.0015 로 유의하였으나, 20 가지 scoring 으로 확장 후 순위 변동이 더 심화되었습니다.)

#### 4.4.3.3 LOPO 교차 검증 — 한 바이러스의 최적이 다른 바이러스에 적용 가능한가?

**왜 필요한가:** ANOVA 와 Friedman 은 “만능 방법이 없다” 를 보여주지만, 실용적 질문은 “그렇다면 새로운 바이러스가 나타났을 때 기존 최적을 적용하면 되는가?” 입니다. LOPO(Leave-One-Pathogen-Out) 는 이 질문에 접근하는 한 가지 방법이지만, 0/11 일치 자체는 무작위 조합 permutation 에서도  $P \approx 0.96$  으로 흔하므로 단독 증거가 아닌 보정 증거 (ANOVA 상호작용 + oracle-vs-generalized MCC 값 0.265) 와 함께 읽어야 합니다.

**방법:** 10 개 병원체에서 가장 좋았던 scoring-detection 조합을 찾고, 이것을 남은 1 개 병원체에 적용합니다. 11 번 반복하여 일치율을 계산합니다.

**결과:** Figure 13 은 각 병원체에 대해 예측 MCC(빨간) 와 실제 최적 MCC(파란) 를 비교합니다.




Figure 8: ANOVA 분산 분해 (11 병원체, 20 scoring, 14 families). scoring × pathogen 상호작용 (29.6%) 이 가장 큰 막대이며, family 주효과 (1.3%) 는 거의 보이지 않을 정도로 작음.




Figure 9: LOPO 교차 검증 (11 병원체). 각 병원체에 대해 나머지 10 개에서 학습한 최적 조합 (빨간) 과 실제 최적 (파란) 을 비교. 0/11 일치는 permutation null 과 정합하므로 ( $P \approx 0.96$ ) 단독 증거가 아닌 ANOVA 상호 작용의 corroboration 으로 해석.

**결과 수치:** 일치율 0/11 (0%), 평균 일반화 MCC = 0.032, **family-level oracle MCC = 0.297**, gap 0.265 (= 0.297 - 0.032). 패밀리 단위 그리드 (280 조합) 와 변이체 단위 그리드 (780 조합) 두 척도가 본문에 함께 나타나는데, 패밀리 단위가 oracle-vs-generalized 격차의 정합 기준이며 변이체 단위 (0.341) 는 더 미세한 ceiling 추정치입니다.

**해석:** 0/11 일치 자체는 permutation null 에서도  $P \approx 0.96$  으로 흔하므로 단독 증거는 아닙니다. 실질적 증거는 **oracle vs generalized MCC 갭 0.265** — 10 개에서 학습한 “최적” 을 11 번째에 적용하면 oracle 대비 평균 0.265 만큼 성능이 하락합니다. 이 갭과 ANOVA 상호작용 ( $\omega^2=0.296$ ) 이 합쳐져 **병원체별 맞춤 방법 선택의 가치**를 뒷받침합니다.

#### 4.4.4 추가 검증: 정밀도, 재현율, DMS 교차 검증 Precision-at-k 분석 (상위 k 개 선택 시 정밀도), DMS 임계값 민감도 분석, Layer A vs Layer C 최적 비교:

Table 20: 6 개 DMS 병원체의 Layer A vs Layer C 최적 점수화 비교

| 바이러스       | Layer A 최적      | MCC_A | Layer C 최적      | MCC_C |
|------------|-----------------|-------|-----------------|-------|
| SARS-CoV-2 | Tranception     | 0.211 | pLDDT inv       | 0.186 |
| H3N2       | FUBAR BF        | 0.534 | semantic change | 0.245 |
| HIV-1      | entropy         | 0.275 | FUBAR           | 0.139 |
| RSV        | ESM-2 LLR       | 0.196 | EVEscape        | 0.180 |
| Rabies     | stability       | 0.248 | homoplasy       | 0.182 |
| EV-A71     | semantic change | 0.260 | pLDDT inv       | 0.322 |

6 개 DMS 병원체 중 5 개에서 Layer A 와 Layer C 의 최적 scoring 이 서로 달라, 두 평가 차원이 독립적임을 확인했습니다.

#### 4.4.5 Stage 2 핵심 발견 요약 8,580 회 평가는 두 개의 1 차 분석 + 두 개의 null-consistent 보정으로 정리됩니다:

**1 차 (positive evidence):** 1. **바이러스마다 잘 맞는 정보가 다릅니다.** 같은 알고리즘을 쓰더라도 어떤 정보 (빈도, 계통, 구조, AI 예측 등) 를 넣느냐에 따라 성능이 크게 달라졌고, 그 차이는 바이러스별로 달랐습니다. 통계적으로도 정보 유형 × 바이러스 효과가 가장 큰 요인이었습니다 ( $\omega^2=0.296$ ). 2. **실제 쓸모는 HIV-1 백신 회피 사례에서 가장 깨끗하게 확인했습니다.** HIV-1 에서는 예측 후보 안에 백신 회피 위치가 무작위보다 7.19 배 더 많이 모였습니다 (Bonferroni  $p=2.5e-16$ ). H3N2 는 기존 정답과 겹치는 부분이 많아 자기 일관성 확인에 가깝고, SARS-CoV-2 는 탐색적 결과로만 봅니다.

**2 차 (null-consistent 보정):** 3. 한 바이러스에서 좋았던 조합이 다른 바이러스에서도 그대로 1 등이 되지는 않았습니다. 다만 이 사실 하나만으로 결론을 내리지는 않고, 정보 유형 × 바이러스 효과와 HIV-1 외부 검증을 함께 근거로 삼습니다. 4. 모든 바이러스에서 항상 우수한 단일 조합은 보이지 않았습니다 (Friedman  $p=0.990$ ).

**증거 등급:** HIV-1 은 기존 정답과 독립적인 검증에 가장 가까워 핵심 근거로 사용합니다. H3N2 는 이미 알고 있던 정답과 많이 겹치므로 보조 확인입니다. SARS-CoV-2 는 통계 보정 후 약해지므로 탐색적 결과입니다.

### 4.5 Information-Type Analysis (정보 유형 분석)

Stage 2 의 14 개 탐지 알고리즘은 모두 빈도/엔트로피 입력에 의존합니다 — 알고리즘을 바꿔도 입력이 같으면 정보의 한계도 같습니다. 이 절은 계통 (homoplasy, FUBAR), 구조 (pLDDT, SASA), AI(ESM-2, Tranception) 등 20 가지 정보 유형으로 확장하여 정보원 자체를 비교합니다.

**4.5.1 각 정보 유형이 핫스팟을 얼마나 잘 구분하는가 (AUC)** Figure 14 은 10 개 정보 유형의 병원체별 판별력 (AUC) 을 히트맵으로 보여줍니다.

10 개 정보 유형 × 11 개 병원체 AUC 히트맵. 초록색이 진할수록 판별력이 높음. 바이러스마다 최고 AUC 위치가 다름.

Table 19 는 단일 정보 유형만으로 핫스팟을 구분했을 때 병원체별 최고 AUC 를 보여줍니다. Norovirus 에서 homoplasy 가 AUC 0.944(거의 완벽) 인 반면 SARS-CoV-2 에서는 0.586(보통) 으로, **같은 정보 유형이라도 바이러스에 따라 판별력이 극단적으로 달라짐**을 확인합니다.

Table 21: 병원체별 최고 판별 정보 유형

| 바이러스       | 가장 효과적인 정보  | AUC          |
|------------|-------------|--------------|
| Norovirus  | homoplasy   | <b>0.944</b> |
| Flu-B      | homoplasy   | <b>0.805</b> |
| H3N2       | pLDDT       | <b>0.787</b> |
| Dengue     | homoplasy   | <b>0.770</b> |
| HIV-1      | entropy     | <b>0.730</b> |
| MERS       | ESM-2 LLR   | <b>0.695</b> |
| HCV        | dN/dS proxy | <b>0.680</b> |
| SARS-CoV-2 | ESM-2 LLR   | <b>0.586</b> |
| RSV        | pLDDT       | <b>0.561</b> |

**4.5.2 바이러스마다 어떤 정보가 가장 중요한가 (Random Forest)** 단일 정보 유형 (4.5.1) 으로는 한계가 있으므로, Random Forest 로 10 가지 feature 를 결합하여 교차검증 AUC 를 측정했습니다. 결합 효과가 가장 큰 병원체는 MERS(단일 0.537 에서 결합 0.875 로 63% 개선) 이고, RSV(0.737) 는 단일 feature 로는 거의 불가능했던 예측이 가능해졌습니다. 아래 표는 병원체별 **가장 중요한 정보 유형 상위 3 개**와 결합 AUC 를 보여줍니다.

Table 22: Random Forest feature 중요도 — 병원체별 상위 3 개 정보와 교차검증 AUC

| 병원체         | 1 위 (카테고리)             | 2 위         | 3 위       | CV AUC |
|-------------|------------------------|-------------|-----------|--------|
| SARS-CoV-2  | <b>ESM-2 LLR (AI)</b>  | Semantic    | pLDDT     | 0.606  |
| H3N2        | <b>pLDDT (구조)</b>      | dN/dS proxy | Homoplasy | 0.791  |
| Norovirus   | <b>Homoplasy (MSA)</b> | Entropy     | Frequency | 0.899  |
| HIV-1       | <b>ESM-2 LLR (AI)</b>  | Entropy     | Homoplasy | 0.802  |
| Dengue      | <b>Homoplasy (MSA)</b> | Frequency   | pLDDT     | 0.781  |
| RSV         | <b>pLDDT (구조)</b>      | ESM-2 LLR   | Stability | 0.737  |
| Influenza B | <b>Homoplasy (MSA)</b> | Frequency   | pLDDT     | 0.756  |
| MERS        | <b>ESM-2 LLR (AI)</b>  | pLDDT       | SASA      | 0.875  |
| HCV         | <b>dN/dS (계통)</b>      | Frequency   | Entropy   | 0.700  |
| Rabies      | <b>pLDDT (구조)</b>      | Stability   | Grantham  | 0.565  |
| EV-A71      | <b>ESM-2 LLR (AI)</b>  | pLDDT       | Semantic  | 0.636  |

1 위 정보의 카테고리가 **AI(4 개), 구조 (3 개), MSA(3 개), 계통 (1 개)** 로 분포하여 어떤 단일 카테고리도 과반을 차지하지 못합니다.

**4.5.3 상관관계 + 제거 실험 + 정답 이질성 점검** 10 개 정보 유형 간 Spearman 상관 (11 병원체 평균). 빈도-엔트로피 상관 0.97(사실상 동일 정보). homoplasy 는 다른 모든 정보와 상관 0.23 이하로 가장 독립적.

Feature 제거 실험. 빨간색 (왼쪽) = 제거 시 성능 하락 (필수 정보). 파란색 (오른쪽) = 제거 시 성능 상승 (잡음 유발 정보).

- **상관 구조:** 빈도-엔트로피  $\rho=0.97$  (사실상 동일 정보), homoplasy 는 다른 모든 정보와  $\rho<0.23$  (가장 독립).
- **제거 실험 (12 병원체 — Zika 포함, feature 분석 확장 scope):** homoplasy 제거 시  $\Delta\text{MCC}=-0.028$  (가장 큰 하락폭이지만 절대 차이는 작음 — 10 개 feature 가 보완적). 4 개 feature 만으로 전체의  $\approx 98\%$  (97.6%; 4-feature MCC 0.081 vs 10-feature 0.083; 차이 0.002 는  $\pm 0.002$  subsampling 범위). ESM-2 LLR/SASA 제거 시 오히려 성능 소폭 상승 — 단 특정 병원체 (SARS-CoV-2, RSV) 에서는 1 위. 11 병원체 한정 재계산 시 baseline 이 0.083  $\rightarrow$  0.093, ordering 은 동일.
- **정답 이질성 점검:** 11 바이러스의 Layer A 80~100% 가 “면역 회피” 유형. 같은 유형임에도 최적 정보가 5 가지로 분화  $\rightarrow \omega^2=0.296$  은 GT 기준 차이가 아닌 **고유한 생물학적 차이**에 기인.

#### 4.5.4 실용적 검증: 실험 탐색 범위를 얼마나 줄일 수 있는가 Vaccine escape enrichment (20 scoring x 39 detectors, 2,340 evaluations):

Table 23: 병원체별 최고 백신 회피 정답 집중 배율

| 바이러스              | 최적 scoring     | 카테고리  | Detection        | Enrichment    | p 값     |
|-------------------|----------------|-------|------------------|---------------|---------|
| <b>H3N2</b>       | FUBAR BF       | 계통발생  | Wavelet(t=2.0)   | <b>9.36 배</b> | <0.0001 |
| <b>HIV-1</b>      | freq           | 빈도 기반 | Wavelet(t=1.5)   | <b>7.19 배</b> | <0.0001 |
| <b>SARS-CoV-2</b> | FUBAR pos.sel. | 계통발생  | FreqThresh(p=85) | <b>7.63 배</b> | 0.026   |

이 결과의 실용적 의미는 **실험 탐색 범위의 축소**입니다. 예를 들어 H3N2 HA 단백질 (543 AA) 에서 핫스팟을 찾으려면 원래 500 개 이상의 위치를 모두 실험해야 합니다. MutBench 의 다중 정보 통합을 사용하면 상위 50 개 위치만 조사하고도 핫스팟을 4 배 더 높은 확률로 포착할 수 있습니다.

Table 24: 탐색 범위 축소 효과

| 접근                              | 탐색 범위           | 정답 집중 배율     | 의미                           |
|---------------------------------|-----------------|--------------|------------------------------|
| 무정보                             | 500 전부          | 1.0 배        | 전수 조사                        |
| 빈도만                             | 상위 50           | 1.7 배        | 약간 개선                        |
| <b>EqualWeight (10-feature)</b> | <b>상위 50</b>    | <b>4.0 배</b> | <b>실험 자원 90% 절감, 포착률 4 배</b> |
| <b>최적 조합 (oracle)</b>           | <b>상위 20-80</b> | <b>7-9 배</b> | <b>이론적 상한</b>                |

#### 교차 검증: 벤치마크 순위와 실제 백신 회피가 일치하는가?

벤치마크 결과가 **실제 공중보건 문제**와 일치하는지 교차 검증했습니다. Layer A 최적 scoring 이 vaccine escape 위치에서도 최고 enrichment 를 달성하는지 확인한 결과:

- **HIV-1** (cleanest external validation): Layer A 최적 = **entropy** (MCC 0.275)  $\rightarrow$  escape 에서도 Frequency 카테고리의 freq 가 최고 (7.19 배, Bonferroni  $p=2.5e-16$ ). entropy 와 freq 는 feature-value 상관  $\rho=0.97$  로 사실상 동일 정보원이므로 category-level 일치. HIV-1 escape 위치의 82% 가 Layer A 와 disjoint 이므로 진짜 외부 검증.
- **H3N2** (self-consistency check): Layer A 최적 = FUBAR BF  $\rightarrow$  escape 에서도 FUBAR BF 가 최고 (9.36 배). 단 H3N2 escape 위치의 69% 가 이미 Layer A 에 포함되어 있어, Layer A-disjoint 9 개 novel 위치만으로 재계산하면 enrichment 7.19 배, Fisher  $p=0.132$ (비유의). 즉  $9.36\times$  는 외부 검증 보다는 Layer A 자체 성능의 재측정 성격이 강합니다.
- **SARS-CoV-2** (exploratory): 7.63 배이지만 Bonferroni 보정 후 유의성 소실. 탐색적 결과로만 취급합니다.

알고리즘 자체는 순환 논리가 아니지만 (Layer A 와 scoring 은 독립적으로 계산됨), HIV-1 이 유일한 정직한 외부 검증 앵커이고 H3N2 는 self-consistency 확인이라는 점을 투명하게 밝힙니다.

EqualWeight 통합의 escape enrichment (top-5% threshold):




Figure 10: 탐색 범위 축소 효과 (H3N2). 무정보 1.0 배에서 EqualWeight 4.0 배, Oracle 7.8 배로 단계적 축소.

Table 25: EqualWeight 다중 정보 통합의 escape enrichment (top-5% threshold)

| 바이러스       | Enrichment | p 값    | 해석                          |
|------------|------------|--------|-----------------------------|
| H3N2       | 4.01 배     | 0.0023 | 유의 — 실험 탐색 4 배 축소           |
| HIV-1      | 4.17 배     | 0.0037 | 유의 — 실험 탐색 4 배 축소           |
| SARS-CoV-2 | 2.67 배     | 0.171  | 비유의 — escape 위치 수 부족 (2/30) |

#### 4.5.5 동등 가중치 (EqualWeight) 의 작동 원리

**핵심 고려사항 7:** 왜 동등 가중치가 자의적 선택이 아닌가?

동등 가중치가 “자의적 선택” 이 아닌 이유: 면역 회피 핫스팟이 되려면 여러 조건이 **동시에** 충족되어야 합니다.

1. 해당 위치에서 변이가 실제로 발생해야 하고 (빈도)
2. 그 변이가 여러 계통에서 독립적으로 반복되어야 하며 (homoplasy)
3. 단백질 구조가 변이를 허용해야 하고 (pLDDT/SASA)
4. 변이가 단백질 기능을 실질적으로 변화시켜야 하며 (ESM-2)
5. 아미노산의 물리화학적 성질이 충분히 달라야 합니다 (Grantham)

이 중 하나라도 충족되지 않으면 핫스팟이 아닙니다. 예를 들어 변이가 자주 일어나도 구조가 허용하지 않으면 바이러스가 죽고, 구조가 허용해도 변이가 발생하지 않으면 회피가 일어나지 않습니다. **동등 가중치는 이 다중 조건을 균형 있게 고려하는 접근이며, 특정 정보에 편향되지 않고 모든 조건을 동시에 평가합니다.**

**적응적 가중치는 왜 실패하는가?**

3 가지 적응적 가중치 전략 모두 EqualWeight 보다 성능 낮음: - kNN-weighted: MCC 0.020 - Top-3 AUC: MCC 0.049 - Correlation-aware: MCC 0.043 - **EqualWeight: MCC 0.083**

원인: 11 개 참조 바이러스로는 13 차원 프로파일 공간이 심각하게 부족 (차원-표본 비 약 1.1). 단, Oracle MCC = 0.160 으로 EqualWeight 의 약 2 배, 이에 따라 20~30 개 이상 병원체 확보 시 적응적 개선 가능.



#### 4.6 PAHD-R 재설계 — “그렇다면 실제로는 어떻게 써야 하는가?”

기존 적응형 가중치 실험의 결론은 “적응형 접근이 틀렸다”가 아닙니다. 더 정확히는 **현재 데이터 수로는 새 바이러스에 맞는 가중치를 자동으로 배울 만큼 충분하지 않다**는 뜻입니다. 그래서 PAHD-R(Pathogen-Aware Hotspot Detection and Review)은 “모든 바이러스를 자동으로 맞히는 만능 예측기”가 아니라, 여러 생물학적 증거를 모아 **실험 후보를 우선순위화하는 검수 프레임워크**로 설계했습니다.

PAHD-R의 핵심 흐름은 다음과 같습니다.

1. 서열, 구조, 계통, AI 보조 정보를 모읍니다.
2. 여러 증거를 한 점수로 합칩니다.
3. 목적에 맞는 세 가지 사용 모드 (Core, Augmented, Review) 중 하나를 고릅니다.
4. 근거가 충분할 때만 바이러스별 보정을 적용합니다.
5. 정확도, 주변 영역 일치도, 상위 후보 정밀도, 위양성률을 함께 보고합니다.

중요한 점은 PAHD-R이 **바이러스마다 완전히 다른 알고리즘을 새로 만드는 방식이 아니라는** 것입니다. 기본 알고리즘은 공통이고, 병원체별 보정은 생물학적 근거와 검수 조건을 통과할 때만 엽니다.

| 모드               | 쉬운 설명                | Exact MCC | ±10 MCC | Precision@20 | Constrained F |
|------------------|----------------------|-----------|---------|--------------|---------------|
| PAHD-R-Core      | AI 의존도를 낮춘 기본형       | 0.1689    | 0.5866  | 0.2111       | 0.11          |
| PAHD-R-Augmented | AI/구조 보조 정보까지 쓰는 균형형 | 0.1680    | 0.6079  | 0.1944       | 0.11          |
| PAHD-R-Review    | 위양성을 줄이는 보수적 검토형     | 0.1666    | 0.6366  | 0.1833       | 0.00          |

세 모드는 모두 기본 검수는 통과했습니다. 다만 한 숫자만 보고 “완성된 예측기”라고 말하면 안 됩니다. 정확히 맞힌 정도, 주변 영역까지 맞힌 정도, 상위 20개 후보의 정밀도, 위양성률을 함께 봐야 합니다.

**4.6.1 왜 세 가지 모드가 필요한가?** PAHD-R는 하나의 숫자로 “최고 알고리즘”을 고르는 대신, 사용 목적에 따라 모드를 나눕니다.

- **Core:** AI 보조 정보에 덜 의존하는 기본형입니다. 설명이 쉽고 검수하기 좋습니다.
- **Augmented:** AI와 구조 정보를 보조로 사용해 후보 영역의 우선순위를 잡습니다.
- **Review:** 후보 수가 줄어도 좋으니 틀린 후보를 줄이고 싶을 때 쓰는 보수적 모드입니다.

즉 PAHD-R는 “정답을 맞히는 단일 예측기”라기보다, **실험 검증 후보를 정렬하고 검수하는 운영 프레임워크**입니다. 현재 논문의 결론은 “adaptive 알고리즘을 완성했다”가 아니라, **adaptive 확장이 가능한 방향과 필요한 검증 조건을 확인했다**에 가깝습니다.

**4.6.2 병원체별 repair layer는 언제 허용되는가?** repair layer는 성능이 좋아 보인다고 바로 채택하지 않습니다. 다음 조건을 통과해야 합니다.

1. 좌표계가 맞는가? 예: 전체 polypeptide 좌표와 국소 단백질 좌표가 섞이지 않았는가.
2. 생물학적 prior가 명확한가? 예: receptor-binding site, known epitope, DPP4 contact.
3. shifted/random decoy control을 통과하는가?
4. permutation audit 또는 외부 검증에서 과장 신호가 아닌가?

이 기준으로 정리하면:

| Repair        | 상태                     | 이유                                                                                                           |
|---------------|------------------------|--------------------------------------------------------------------------------------------------------------|
| HCV E2 repair | 채택 가능한 optional repair | H77 E2 좌표 불일치를 보정한 뒤 Core/Augmented exact MCC 0.5257, constrained FPR 0.0000. permutation/shifted control 통과 |

| Repair                     | 상태  | 이유                                                                                                                 |
|----------------------------|-----|--------------------------------------------------------------------------------------------------------------------|
| SARS-CoV-2 RBD/ACE2 repair | 후보  | PAHD-R-Review 에서 exact MCC 0.2304, $\pm 10$ MCC 0.8761 까지 개선되지 만 Precision@20 이 0.1000 이고 local DMS Layer C 검증은 보류 |
| MERS DPP4/contact repair   | 후보  | DPP4 contact prior 는 타당 하지만 Layer A 양성이 희소 하고 수동 구조 좌표 검토 필요                                                       |
| RSV repair                 | 미채택 | 현재 repair 아이디어가 검수 조건을 충분히 통과하지 못함                                                                                 |

#### 4.6.3 추가 후보들은 왜 기본값이 아닌가? 추가 sweep 에서 몇 가지 좋은 후보가 나왔습니다.

| 후보                      | 결과                       | 해석                                   |
|-------------------------|--------------------------|--------------------------------------|
| PAHD-R-Core-Calibrated  | 일부 지표가 Core 보다 조금 좋아짐    | 병원체별 검수에서 약점이 있어 기본값으로 채택하지 않음       |
| ShrinkCompact           | 위양성률은 낮아짐                | 너무 조심스러워 놓치는 후보가 늘 수 있음              |
| ShrinkRegion            | 주변 영역 기준 성능은 좋음          | 무작위/이동 대조군 검수에서 기본값으로 부족             |
| Virus-aware hybrid      | Core-Calibrated 와 비슷한 후보 | 기존 채택 모드를 대체할 만큼 충분히 강하지 않음          |
| Selective callable-only | 성능이 좋아 보임                | 9 개 중 4 개 바이러스에만 답하므로 전체 성능으로 볼 수 없음 |

최종 판단은 명확합니다. **Core, Augmented, Review** 는 현재 사용 가능한 모드로 채택하고, 나머지는 후속 검증 후보로 남깁니다. 같은 데이터에서 계속 조정하면 숫자는 조금 좋아질 수 있지만, 그것이 진짜 개선인지 과 적합인지 구분하기 어렵습니다. 그래서 이지가이드와 논문 모두 “가능성을 확인했다” 는 기조로 설명합니다.

#### 4.6.4 발표용 쉬운 설명 PAHD-R 를 한 문장으로 설명하면 다음과 같습니다.

PAHD-R 는 바이러스마다 새 AI 모델을 만드는 방법이 아니라, 여러 생물학적 증거를 공통 규칙으로 합쳐 실험 후보를 정렬하고, 검수를 통과한 경우에만 바이러스별 보정을 허용하는 방법입니다.

말하면 안 되는 표현:

- “PAHD-R 는 모든 바이러스에 통하는 만능 예측기다.”
- “PAHD-R 는 AI 가 정답을 내는 예측 모델이다.”
- “SARS-CoV-2 와 MERS repair 가 최종 채택됐다.”
- “일부 바이러스에만 답한 selective 결과를 전체 9 개 바이러스 성능처럼 말한다.”
- “pooled permutation 을 통과했으니 병원체별 null 도 모두 통과했다.”

말해도 되는 표현:

- “PAHD-R 는 검수 범위가 정해진 생물학적 증거 통합 프레임워크다.”
- “채택 모드는 Core, Augmented, Review 세 가지다.”
- “HCV repair 만 optional adopted repair 다.”
- “SARS-CoV-2, MERS repair 와 calibrated/shrinkage/virus-aware/selective 변형은 후보로 남긴다.”
- “추가 채택은 외부 검증, time-forward 검증, tree/bootstrap 검증 이후로 미룬다.”

## Chapter 5. Discussion (논의)

### 5.1 Methodological Validity of MutBench (방법론 타당성)

**5.1.1 결과의 통계적 신뢰 구간** Stage 2의 MCC 값이 단일 계산에서 우연히 나온 것이 아닌지 확인하기 위해, BCa(편향 보정) bootstrap 으로 95% 신뢰 구간을 산출했습니다. MutClust-Hybrid의 hotspot-score 95% CI는 [0.323, 0.635]로, 신뢰 구간이 0을 포함하지 않아 결과가 통계적으로 유의함을 확인합니다.

**5.1.2 합성 데이터와 실제 데이터의 성능 격차** 합성 데이터 ( $F1=0.785$ )와 실제 GISAID 데이터 ( $F1=0.123$ ) 사이의 큰 격차는 벤치마크의 약점이 아니라 **H-score 분포의 구조적 차이** 때문입니다. 실제 데이터에서는 29,903 위치 중 1.14%만 H-score가 비영점이어서 탐지 알고리즘이 작동할 수 있는 위치 자체가 극히 적습니다. 그럼에도 enrichment는 6.9~8.0 배를 유지하여, 탐지된 위치는 **생물학적으로 의미 있는 영역에 집중되어** 있음을 보여줍니다. 이 합성-실제 격차 자체가 방법론적 기여입니다 — 두 환경에서의 성능을 모두 측정함으로써 방법의 이론적 능력과 현실적 한계를 동시에 파악할 수 있습니다.

**5.1.3 정답 기준과 탐지 방법이 독립적인가** 벤치마크의 신뢰성을 위해서는 정답 (3 층 GT)이 특정 탐지 방법에 유리하게 편향되지 않아야 합니다. 이를 두 가지 방법으로 확인했습니다. 첫째, Layer A(수렴 진화)는 문헌에서, Layer C(DMS)는 실험실에서 독립적으로 정의되어 탐지 방법과 무관합니다. 둘째, 탐지된 핫스팟이 3D 단백질 구조에서도 공간적으로 클러스터링됨을 확인했습니다 (5.92 배 spatial contact enrichment,  $z=13.34$ ). 이는 탐지 결과가 서열 수준뿐 아니라 구조 수준에서도 생물학적 의미를 가짐을 보여줍니다.

### 5.2 Limitations of H-score-Based Detection (H-score 한계)

**5.2.1 참조 서열 고정에 따른 편향** H-score는 참조 서열 (Wuhan-Hu-1)을 기준으로 변이 빈도를 계산하므로, **founder effect에 취약**합니다. 시뮬레이션에서 founder mutation(빈도 90%, 단일 기원)과 수렴 진화(빈도 낮지만 15 번 독립 발생)를 비교한 결과, H-score는 100%의 경우에서 founder mutation에 가장 높은 점수를 부여했습니다. 또한 H-score 순위와 독립 발생 횟수 (homoplasy) 사이의 상관관계는  $\rho = -0.876$  (강한 음의 상관)으로, **H-score가 높은 위치일수록 오히려 독립적 수렴 진화가 적다**는 것을 의미합니다. 이것이 빈도 기반 scoring의 근본적 한계이며, Stage 2에서 homoplasy, FUBAR 등 대안 정보 유형이 필요한 이유입니다.

#### 5.2.2 MCC 수치의 해석

**핵심 고려사항 8:** Oracle MCC=0.341이 왜 상대적으로 낮은가, 그리고 generalized MCC=0.032는 왜 0 근처인가?

면역 회피 핫스팟을 완벽히 예측하려면 “항체가 어디를 공격하는가”를 알아야 합니다. 그런데 이 정보는 사실상 **정답 자체**입니다 — 항체가 결합하는 위치가 곧 면역 회피가 일어나는 위치이므로, 이것을 feature로 쓰면 “**답을 보고 시험 치는 것**”이 됩니다.

따라서 다중 정보 통합 분석은 **정답 없이 사용 가능한 서열/구조 정보만으로** 탐색 범위를 줄여주는 접근이며, 이것이 현실적으로 달성 가능한 최선입니다. Oracle MCC = 0.341이 “낮아 보이는” 것은 이 근본적 제약 때문이지 방법의 실패가 아닙니다.

**5.2.3 영역 수준으로 완화하면 성능이 어떻게 달라지는가** MCC 평가에서 정답 위치에서 1 칸만 벗어나도 오답으로 처리됩니다. 하지만 실제로 핫스팟은 “영역”이지 정확한 1개 위치가 아닙니다. 평가 기준을 항원 에피토프 크기 ( $\pm 10$  위치)로 완화하면:

Exact(정확히 일치) 기준 MCC 0.289가  $\pm 5$  위치 완화 시 0.638,  $\pm 10$ (약 1개 에피토프 크기) 완화 시 **0.712**로 상승합니다. 특히 H3N2는  $\pm 10$ 에서 MCC 0.964에 도달합니다.

탐지 결과가 정답과 “정확히” 일치하지 않더라도 **가까이에 위치**합니다. Exact 평가는 보수적이며, 실제 생물학적 의미에서는 방법들의 성능이 훨씬 높습니다.

Table 29: 병원체별 영역 완화 MCC 분석

| 바이러스        | Exact        | $\pm 5$ window | $\pm 10$ window |
|-------------|--------------|----------------|-----------------|
| HCV         | 0.660        | 0.588          | 0.519           |
| H3N2        | 0.534        | 0.639          | 0.548           |
| Norovirus   | 0.510        | 0.335          | 0.275           |
| Influenza B | 0.392        | <b>0.894</b>   | <b>0.924</b>    |
| HIV-1       | 0.275        | 0.406          | 0.343           |
| Dengue      | 0.274        | 0.441          | 0.508           |
| EV-A71      | 0.260        | 0.275          | 0.199           |
| Rabies      | 0.248        | 0.265          | 0.266           |
| SARS-CoV-2  | 0.211        | 0.480          | 0.497           |
| MERS        | 0.196        | 0.470          | 0.593           |
| RSV         | 0.196        | 0.394          | 0.318           |
| 평균          | <b>0.341</b> | <b>0.472</b>   | <b>0.454</b>    |

일부 병원체 (HCV, Norovirus) 는 윈도우 확장 시 MCC 가 오히려 하락 — oracle 탐지가 이미 정밀하여 확장이 precision 을 희석시킴.

**5.2.4 계통수 기반 점수 (homoplasy) 의 가능성과 한계** HIV-1 에서 AUC=0.71 (우수), HCV 에서 AUC=0.39 (실패 — parsimony 포화: 변이가 너무 많아 계통수 복원이 한계에 달해 homoplasy 계산이 부정확해지는 현상).

### 5.3 Cross-Pathogen Generalization (교차 병원체 일반화)

**5.3.1 교차 병원체 일반화 실패의 실용적 함의** LOPO 0/11 이라는 결과의 실용적 의미는 명확합니다. 새로운 바이러스 (예: 신종 코로나바이러스) 가 출현했을 때, 기존에 알려진 최적 방법 (예: H3N2 에서 FUBAR 가 최고) 을 그대로 적용할 수 없습니다. 대신 해당 바이러스의 서열 데이터를 수집한 후 MutBench 파이프라인으로 병원체별 벤치마크를 수행하여 최적 정보 유형을 새로 식별해야 합니다.

**5.3.2 선행 연구와의 결론 비교** “최적 방법이 바이러스마다 다르다” 는 MutBench 의 핵심 결론이 기존 연구들과 어떻게 관련되는지를 확인합니다. Table 24 는 각 선행 연구의 결론과 MutBench 의 발견이 같은 방향인지, 다른 점은 무엇인지를 비교합니다.

Table 30: 선행 연구와 MutBench 결론 비교

| 선행 연구                 | 그들의 결론                                  | MutBench 와 동일? | 차이점                                                 |
|-----------------------|-----------------------------------------|----------------|-----------------------------------------------------|
| <b>EVEREST (2025)</b> | 최적 VEP 방법이 바이러스마다 다름                    | 동일 방향          | EVEREST 는 per-mutation 예측, MutBench 는 per-region 탐지 |
| <b>Maher (2022)</b>   | SARS-CoV-2 에서 다중 feature 결합이 단일보다 우수    | 동일             | MutBench 는 이를 11 개 바이러스로 일반화                        |
| <b>Hie (2021)</b>     | PLM semantic similarity 가 escape 예측에 유효 | 부분 동일          | EV-A71 에서 최적이거나 다른 바이러스에서는 아님<br>→ 병원체 의존적          |

| 선행 연구                    | 그들의 결론                    | MutBench 와 동일? | 차이점                             |
|--------------------------|---------------------------|----------------|---------------------------------|
| <b>Bailey (2018)</b>     | 암 driver 도구들이 서로 다른 결과 산출 | 유사 패턴          | 바이러스에서도 동일 패턴, 병원체 생물학이 원인      |
| <b>ProteinGym (2023)</b> | VEP 성능이 단백질마다 다름          | 동일 방향          | MutBench 는 정보 유형이 핵심 요인임을 추가 규명 |

**MutBench 의 고유 기여:** 병원체 의존성을 분산 분해로 정량화 (modeled  $\omega^2=0.296$ , 20-type; 0.103, 6-category lower bound; within-cell residual  $\omega^2\approx 0.39$ ) 하고, HIV-1 7.19 배 vaccine escape enrichment(Layer A-disjoint 82%, Bonferroni  $p=2.5e-16$ ) 를 primary external validation 으로 제시한 점.

**5.3.3 탐지 성능의 이론적 상한 — 다른 분야와 비교** EqualWeight MCC 0.083 은 다른 분야의 유사한 과제와 비교하면 맥락을 이해할 수 있습니다. 위치 수준 (position-level) 에서 극심한 불균형 (양성 1~5%) 하에 이진 분류를 수행하는 과제들은 모두 MCC 가 낮습니다.

Table 31: 다른 분야 position-level 예측 성능 비교

| 비교 대상           | 과제                    | 성능               | 양성 비율       |
|-----------------|-----------------------|------------------|-------------|
| 암 드라이버 유전자      | position-level        | MCC 0.1~0.3      | 1~5%        |
| 전사인자 결합 부위      | position-level        | F1 0.3~0.5       | 1~3%        |
| <b>MutBench</b> | <b>position-level</b> | <b>MCC 0.083</b> | <b>2~5%</b> |

MutBench 의 MCC 는 이 범위의 하단에 위치하지만, 평가 기준을 영역 수준 ( $\pm 10$  위치) 으로 완화하면 MCC 가 0.712 로 상승합니다. 이는 탐지된 위치가 정답에서 크게 벗어나지 않으며, 실험 탐색 범위를 줄이는 실용적 목적에는 충분함을 의미합니다.

## 5.4 Practical Implications (실용적 함의)

**5.4.1 백신 회피 위치를 사전에 식별할 수 있는가 (Stage 1)** 벤치마크 결과가 실제 공중보건에 유용한지를 검증하기 위해, 실험적으로 확인된 백신 회피 (vaccine escape) 위치를 외부 정답으로 사용합니다. 탐지 방법이 이 위치를 사전에 얼마나 잘 식별하는지를 enrichment(정답 집중 배율) 로 측정합니다. enrichment 가 1.0 보다 높으면 랜덤보다 잘 찾는 것이고,  $p$  값이 0.05 미만이면 통계적으로 유의합니다.

Table 32: 백신 회피 검증 (Stage 1)

| 병원체        | Escape 위치 수 | Best recall   | Enrichment   | p-value    |
|------------|-------------|---------------|--------------|------------|
| SARS-CoV-2 | 34          | 25/34 (0.735) | $4.90\times$ | $< 0.0001$ |
| H3N2       | 25          | 6/25 (0.240)  | $2.10\times$ | 0.054      |
| HIV-1      | 45          | 3/45 (0.067)  | $0.35\times$ | 0.997      |

Stage 1(단일 scoring) 에서 HIV-1 은 enrichment  $0.35\times$  로 완전히 실패했습니다. 반면, Stage 2(20 가지 scoring) 에서는  $7.19\times$  로 대폭 개선되어, 다양한 정보 유형이 필요하다는 것을 직접 증명합니다.

SARS-CoV-2 에서 최고 방법이 34 개 중 25 개 탐지 (recall 73.5%, 4.9 배 enrichment).

**5.4.2 벤치마크 순위와 실제 백신 회피가 일치하는가 v98 의 핵심 추가 검증:** 3 개 병원체, 2,340 회 evaluation 에서 Layer A 최적 = escape 최적이라는 교차 검증 달성. 이것은 DMS 데이터 없는 5 개 바이러스에서 Layer A 의 타당성을 뒷받침하는 독립 증거.

**5.4.3 새로운 병원체에 MutBench 를 적용하는 실무 절차** 새로운 바이러스에 MutBench 적용하는 4 단계 워크플로우:

1. **서열 수집**: 200 개 이상, MAFFT 로 MSA 구축 (~5 분)
2. **Feature 계산**: freq/entropy (초), homoplasy (2~5 분), ESM-2 (3~5 분, GPU), 구조 (AlphaFold2)
3. **Scoring 카테고리 선택**: 아래 추천표 참고
4. **탐지 및 평가**: KDE 또는 Wavelet 기본값 적용 (병원체당 3 초 미만, pre-computed features 기준)

전체 소요시간: **15~20 분** (GPU 탑재 워크스테이션)

Table 33: 바이러스 패밀리별 추천 점수화 카테고리

| 바이러스 패밀리                 | 추천 Scoring              | 근거                    |
|--------------------------|-------------------------|-----------------------|
| Orthomyxoviridae (인플루엔자) | Phylogenetic (FUBAR)    | 강한 다양화 선택 신호          |
| Coronaviridae (코로나)      | AI-based (PLM)          | 얕은 계통; PLM 이 넓은 맥락 포착 |
| Caliciviridae (노로)       | MSA-derived (homoplasy) | epoch 진화에서 수렴 패턴      |
| Retroviridae (HIV)       | MSA-derived (entropy)   | 높은 다양성; 대립유전자 변이 포착   |
| Flaviviridae (HCV, 뎅기)   | Frequency-based         | 초변이 영역이 신호 지배         |
| Pneumoviridae (RSV)      | AI-based (ESM-2)        | 제한된 계통발생 신호           |

**5.4.4 주요 한계 (Ch6 표 참조)** 세 가지 주요 한계 — (i) H-score 가 founder effect 보정 불가 (homoplasy 로 부분 보정; H-score vs homoplasy  $\rho=-0.107$ ), (ii) ESM-2 학습 데이터에 벤치마크 서열 포함 가능성 (Norovirus/HIV 저성능이 그 한계 시사), (iii) Layer A 정의 병원체 이질성 (수렴 진화·HVR·면역 회피 혼합) — 은 6.2 한계 표에 통합 정리.

## Chapter 6. Conclusion (결론)

### 6.1 Summary of Research Contributions (기여 요약)

#### 기여 1: MutBench 벤치마크 프레임워크

바이러스 핫스팟 탐지 분야 최초의 체계적 비교 기준. - 11 개 바이러스, 20 가지 점수화 유형 (6 개 카테고리), 14 개 탐지 방법 패밀리 (5 개 카테고리, 39 개 파라미터 변형), 3 층 정답 기준 - **8,580 회** 대규모 평가

#### 기여 2: 바이러스마다 맞는 정보가 다르다는 발견

핵심 메시지는 단순합니다. - 하나의 만능 알고리즘보다 **바이러스에 맞는 정보 선택**이 더 중요했습니다. - 통계적으로도 “정보 유형 × 바이러스” 효과가 가장 큰 요인이었습니다 ( $\omega^2=0.296$ ). - HIV-1 에서는 백신 회피 위치가 후보 안에 무작위보다 7.19 배 더 많이 모여 실제 활용 가능성을 뒷받침했습니다. - 모든 바이러스에서 항상 1 등인 조합은 보이지 않았습니다.

#### 기여 3: 다중 정보 통합 인프라 (3a) + 외부 백신 회피 검증 (3b)

**(3a) 통합 인프라:** 4 개 핵심 정보 (homoplasy, pLDDT, entropy, freq) 로 전체 10-feature 성능의  $\approx 98\%$  (97.6%) 달성. EqualWeight 통합으로 H3N2 vaccine escape **4.012 배** ( $p=0.0023$ ), HIV-1 **4.17 배** ( $p=0.0037$ ) — 단일 정보로는 불가능한 통계 유의 enrichment.

**(3b) 외부 검증:** 가장 신뢰할 수 있는 외부 검증 사례는 HIV-1 입니다. H3N2 는 기존 정답과 겹치는 부분이 많아 보조 확인으로, SARS-CoV-2 는 통계 보정 후 약해져 탐색적 결과로 해석합니다.

### 6.2 Limitations (한계)

Table 34: 한계점 요약 (cycle 12 추가 항목 포함)

| 한계                          | 설명                                                                                                                        | 경감 요인                                                                                                                                                                                                                                                                                                                                                                           |
|-----------------------------|---------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| GT 불완전<br>Layer A 이질성       | DMS 데이터 6/11 병원체만 병원체별 정의 다름 (수렴 진화·면역 회피·HVR)                                                                            | Layer A 만으로 MCC 평가 가능<br>Ch3 에 명시; <b>실제 ANCOVA fit (statsmodels Type II):</b> 길 이/positive-rate covariate 추가 시 scoring×pathogen $\omega^2$ 0.234 → <b>0.264 로 증가</b> (pathogen 주효과는 0 으로 흡수). <b>부분집합 robustness:</b> HCV 제외 ( $n=10$ ) $\omega^2=0.199$ , HCV+Norovirus 제외 ( $n=9$ ) $\omega^2=0.187$ — 모두 Cohen medium-large. HIV-1 Layer A 23 vs 26 은 binary label 이라 결과 무관 |
| RNA 바이러스만                   | DNA 바이러스 (HPV, HBV) 미포함                                                                                                   | 변이 메커니즘이 다르므로 별도 검증 필요                                                                                                                                                                                                                                                                                                                                                          |
| Founder effect              | H-score 파이프라인 내 직접 보정 미통합                                                                                                 | Homoplasy + FUBAR scoring 으로 보완                                                                                                                                                                                                                                                                                                                                                 |
| dN/dS proxy                 | 단백질 수준 proxy, 빈도와 $r=0.87$                                                                                                | FUBAR 는 codon alignment 직접 사용                                                                                                                                                                                                                                                                                                                                                   |
| 적응적 가중치<br>PAHD-R 후보 과적합 위험 | 11 개 병원체로 학습 부족<br>calibrated/shrinkage/virusCore/Augmented/Review 만 채택하고, 후보들은 외부·time-forward·tree/bootstrap 검증 전까지 미채택 | Oracle MCC 0.160 → 확장 시 개선 가능<br>Core/Augmented/Review 만 채택하고, 후보들은 외부·time-forward·tree/bootstrap 검증 전까지 미채택                                                                                                                                                                                                                                                                   |
| PAHD-R 병원체별 null 약점         | pooled permutation 은 통과했지만 일부 병원체별 null 은 약함                                                                              | $\pm 10$ MCC 단독 보고 금지; exact MCC, Precision@20, constrained FPR, coverage 동시 보고                                                                                                                                                                                                                                                                                                 |

| 한계                        | 설명                                                    | 경감 요인                                                                                                                                                                                                                                                                                            |
|---------------------------|-------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| n=11 통계 한계                | mixed-effects 신뢰 어려움; LOPO 0/11 은 random null 과 구별 약함 | <b>Bayesian partial-pooling 실제 fit (PyMC, half-Cauchy prior):</b> posterior $\omega^2 = 0.252$ , 95% HDI [0.188, 0.314], $\Pr(>0.14)=99.6\%$ — fixed-effect 0.296 약간 아래지만 Cohen large 99.6% 확률. 방향성 robust. <b>ART ANOVA(rank-scale):</b> $\omega^2=0.277$ , $p=8.6e-141$ — distribution-free 확인 |
| 독립 재현                     | 단일 코드베이스·단일 팀·단일 GISAID 스냅샷                           | seed/스크립트 공개; multi-tool 재현은 Priority 5                                                                                                                                                                                                                                                          |
| 동시기 벤치마크 head-to-head 미수행 | ViroGym/EVEREST v3/PLANT 와 task 가 달라 직접 비교 보류         | task-aligned subset 평가는 defense-week sprint                                                                                                                                                                                                                                                      |

### 6.3 Future Research Directions (향후 연구)

Table 35: 향후 연구 로드맵 (cycle 12 priorities 5/6 신설)

| 우선순위 | 방향                | 내용                                                                                                                                                   |
|------|-------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1    | 계통 보정 통합          | TreeTime 파이프라인을 H-score 입력으로 결합                                                                                                                      |
| 2    | 적응적 방법 선택         | 20~30+ 병원체 확장 + meta-learning. PAHD-R 후보 채택은 외부 검증, time-forward 검증, tree/bootstrap 이후로 보류                                                           |
| 3    | DNA 바이러스          | HPV, HBV 등으로 벤치마크 확장                                                                                                                                 |
| 4    | 실시간 감시            | Nextstrain 통합                                                                                                                                        |
| 5    | 통계 robustness 묶음  | Bayesian partial-pooling (n=11), ART ANOVA, ANCOVA(길이/positive rate), $\alpha=0.01$ sensitivity, HIV-1 novel-only Fisher p (37 위치), multi-tool 독립 재현 |
| 6    | provenance + 보충 표 | DMS preprocessing 표 확장, CSV→table 매핑 manifest, Bonferroni-survivor 중앙값 컬럼, Tajima/CUSUM 인용 정리                                                        |

### 6.4 Concluding Remarks (맺음말)

**Take-home (한 문장):** 바이러스 변이 핫스팟을 찾을 때 가장 중요한 질문은 “어떤 알고리즘을 쓸까?” 보다 “이 바이러스에는 어떤 생물학적 정보가 믿을 만한가?” 입니다.

11 개 RNA 바이러스에서 8,580 번 비교한 결과, 바이러스마다 잘 맞는 정보가 달랐습니다. 이 차이는 통계적으로도 가장 큰 성능 요인이었고 ( $\omega^2=0.296$ ), HIV-1 에서는 백신 회피 위치를 무작위보다 7.19 배 더 잘 모아 찾아 실제 활용 가능성을 확인했습니다. PAHD-R 은 이 결론을 바탕으로 실험 후보를 우선순위화하는 세 가지 사용 모드로 정리되었습니다.

앞으로는 바이러스 특성에 맞는 정보 유형을 선택·통합하는 접근이 필요하며, 병원체 참조 데이터베이스의 확장이 적응적 방법 선택의 핵심 과제입니다.



## 부록: 최종 상태 요약 (v229, 2026-05-04)

### 정체성 재정의: wet-lab triage 도구

학위논문 v220→v229 정리 과정에서 MutBench 의 정체성이 명확해졌습니다.

- **deployable detector가 아닙니다.** P5 abstention 규칙 하에 0/12 callable — 어떤 병원체도 prospective 배포 가능 판정을 못 받음
- **wet-lab 실험 우선순위 도구입니다.** 단백질당 ~1,000 위치 → 10–50 후보 압축, 7–9× escape 농축
- **일반화 알고리즘은 n=11 패널에서 본질적으로 학습 불가.** 이건 실패가 아니라 panel-size threshold 본질을 정량화한 contribution

### Phase 4 평가 결과 (10 명 분산 평가, 2-stage hybrid)

| 평가                  | PDF   | 점수           | 통과                      |
|---------------------|-------|--------------|-------------------------|
| v6 (single-read)    | 215pp | 77.52        | conditional (skill 정본만) |
| v8 (2-stage hybrid) | 197pp | <b>83.63</b> | ☑ 모든 게이트                |
| v9 (post-cleanup)   | 197pp | <b>83.31</b> | ☑ 모든 게이트 (current)      |

Phase 4 모든 게이트 PASS: 총점  $\geq 80$ , item 별 mean  $\geq 6$ , skill 정본 mean  $\geq 7$  + 개별  $\geq 5$

### Layer C wet-lab 검증 (재배치된 anchor)

실용가치는 vaccine escape 3 개 (HIV-1, H3N2, SARS) 만이 아니라 **Layer C DMS 6/11 pathogens** 가 메인 anchor:

| Pathogen   | n_gt_c | Best Layer C scoring           | Best Layer C MCC |
|------------|--------|--------------------------------|------------------|
| SARS-CoV-2 | 247    | plddt_inv + KDE(p=75)          | 0.186            |
| H3N2       | 112    | semantic_change + KDE(p=80)    | 0.245            |
| HIV-1      | 48     | fubar + Wavelet(t=2.0)         | 0.139            |
| RSV        | 101    | EVescape_composite + KDE(p=75) | 0.180            |
| Rabies     | 87     | homoplasy + ScoreDBSCAN(ep=8)  | 0.182            |
| EV-A71     | 55     | plddt_inv + Wavelet(t=1.5)     | <b>0.322</b>     |

EV-A71 0.322 + H3N2 0.245 가 가장 강력한 functional anchor. 6 개 모두에서 Layer A 최적  $\neq$  Layer C 최적 → 두 평가 차원 독립 확인.

### 분량 sweet spot 발견

flow-improve 실험 (experiments/flow-improve branch, 폐기) 결과: - 197pp (v9 baseline): 83.31 — sweet spot - 158pp (Aggressive 삭제): v10 81.85 (-1.46) - 153pp (부분 롤백): v11 80.86 (-0.99)

더 짧게 만들면 점수 하락. 표/figure 는 evidence 신뢰도에 직접 영향 — prose 만으로는 strict reviewer 설득 불가. 197pp 가 evidence + flow 균형 sweet spot.

### Defense readiness

- **Master:** v229 (commit aa13920), 197pp, 83.31 PASS
- 모든 4 gate 통과 (Phase 4 80 / item  $\geq 6$  / skill mean  $\geq 7$  / individual  $\geq 5$ )

- Hidden issues 49 건 (chapter-deep), 0 framing inconsistencies, 0 orphan refs
- Visual layout 검증 완료 (6 개 핵심 페이지 sample)
- defense-ready ☑ GREEN